Estatística: Aplicação ao Sensoriamento Remoto

SER 204 - ANO 2024

Estimação Pontual

Camilo Daleles Rennó
camilo.renno@inpe.br
http://www.dpi.inpe.br/~camilo/estatistica/

Inferência Estatística

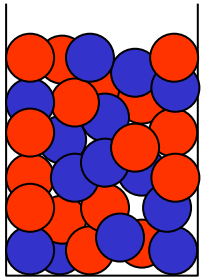

Considere o experimento: retiram-se 3 bolas de uma urna (com reposição). Define-se uma v.a. X cujo valor representa o número total de bolas vermelhas dentre as 3 escolhidas. Qual a média e variância de X?

Quais os valores possíveis de X?

Valores inteiros (número de tentativas bem-sucedidas)
Mínimo 0 (nenhuma bola vermelha)
Máximo 3 (todas 3 são bolas vermelhas)
X: $\{0, 1, 2, 3\}$

Qual a distribuição de probabilidade de X?

X é discreto
A probabilidade de sucesso p é igual para todas tentativas (sorteio com reposição)
O número de sorteios é pré-definido ($n = 3$) e o número de sucessos é a v.a. X
Distribuição: Binomial

Quais os parâmetros que definem esta Binomial?

n e p
$n = 3$
$p = ?$ (precisaria conhecer toda a população)

DISTRIBUIÇÃO CONHECIDA
PARÂMETRO(S) DESCONHECIDO(S)

Inferência Estatística

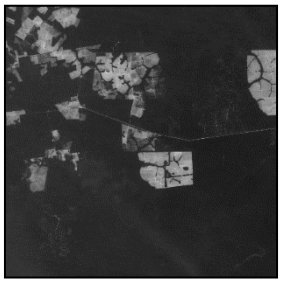

Numa imagem, um *pixel* é selecionado ao acaso. Define-se uma v.a. X cujo valor representa seu valor digital. Qual a probabilidade deste *pixel* possuir valor entre 100 e 150?

Quais os valores possíveis de X?
Considerando uma imagem 8 *bits*...
Mínimo 0 (região escura)
Máximo 255 (região clara)
X: {0, 1, ..., 255}

Qual a distribuição de probabilidade de X?
X é discreto
Distribuição: Desconhecida (discreta)

Que parâmetros são necessários para definir esta distribuição?
??????

DISTRIBUIÇÃO DESCONHECIDA

Inferência Estatística

inferir certas características
da população

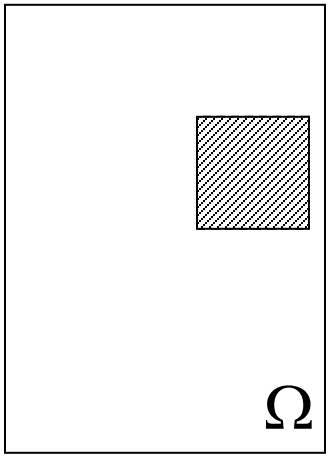

amostra

n elementos (ou objetos) da população
ex: sortear n *pixels* de uma imagem
(com ou sem reposição)

n realizações da v.a.
ex: medir a reflectância de um objeto
n vezes

distribuição desconhecida
e/ou
parâmetros desconhecidos

⇓

a amostra constitui um conjunto de n v.a.
$X_1, X_2, \ldots, X_n$ com mesma distribuição (conhecida ou não)

⇓

Amostra Aleatória

Amostra Aleatória

Como uma amostra aleatória é um conjunto de n v.a.:

cada amostragem resulta num conjunto distinto de valores e portanto pode levar a uma conclusão distinta

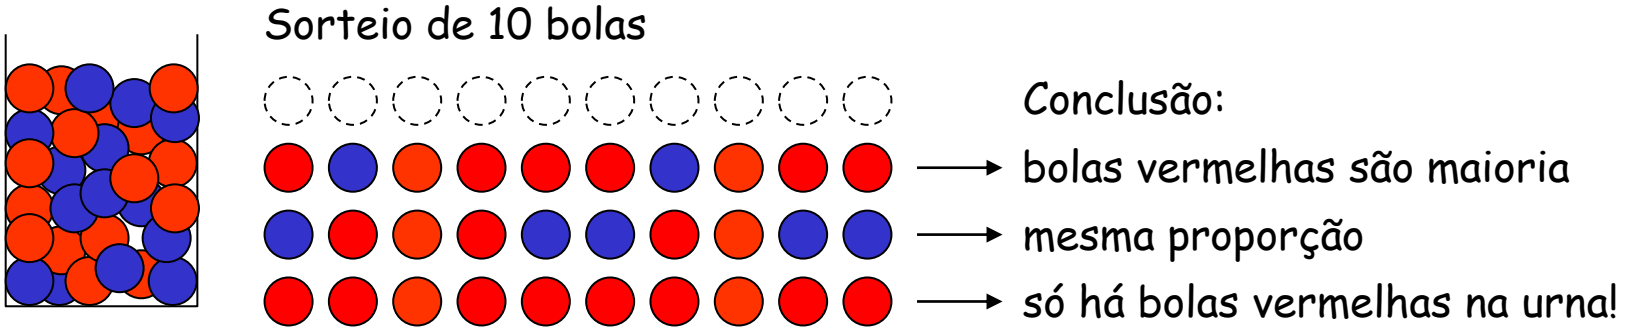

Grandes questões:

- Quão representativa é a amostra disponível para a análise?
  tamanho de amostra e métodos de obtenção das amostras
- Que características devem ser observadas para representar a população?
  estimação de parâmetros
- Quão confiável é conclusão obtida pela pesquisa?
  erros

Estimação de Parâmetros

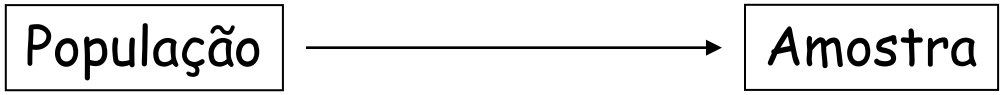

Distribuição de Probabilidade (ou FDP) Distribuição Amostral (Frequências)

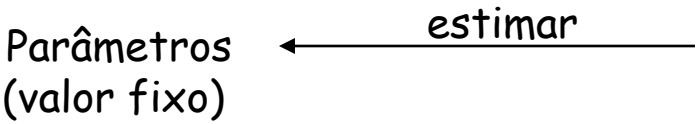

Estimação
- pontual (estatísticas)
- por intervalo (intervalos de confiança)

OBS: estatística: é a v.a. que estima (pontualmente) um parâmetro (populacional)
as vezes é chamada simplesmente de estimador
estimativa: é o valor do estimador obtido para uma amostra específica

Distribuição Amostral

É muito comum utilizar um conjunto de valores observados (amostra) para tentar "enxergar" a verdadeira distribuição da população.

Esta capacidade, é claro, depende do tamanho e representatividade da amostra.

Obs1: Tipos de amostragem e tamanho ideal de uma amostra serão discutidos em "Teoria de Amostragem".

Obs2: Testes estatísticos formais que visam comprovar se uma população segue ou não uma distribuição específica serão discutidos durante o curso.

Existem pelos menos 3 representações gráficas que podem ser utilizadas para avaliar a distribuição amostral:

- histograma (gráfico de frequências)
- frequência acumulada
- boxplot

Estimação Pontual de um Parâmetro

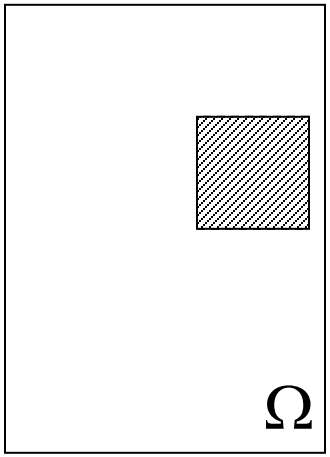

amostra composta por n valores

parâmetro desconhecido θ

De que maneira os valores da amostra podem ser combinados a fim de se produzir uma "boa" estimativa desse parâmetro θ?

- método dos momentos
- método da máxima verossimilhança

$\Rightarrow$ é preciso conhecer a distribuição!

Estimação Pontual de um Parâmetro

Considere que seja possível produzir m diferentes estimadores para θ, sendo que $\hat{\theta}_i$ representa o i-ésimo estimador de θ $(i = 1, ..., m)$

Como escolher qual estimador é melhor?

Importante:

- lembre-se que todo estimador é uma v.a. e portanto seu valor (estimativa) varia de amostra para amostra
- dificilmente (ou é improvável) que uma amostra forneça uma estimativa igual ao parâmetro que se deseja estimar

Estimação Pontual de um Parâmetro

Considere que seja possível produzir m diferentes estimadores para θ, sendo que $\hat{\theta}_i$ representa o i-ésimo estimador de θ $(i = 1, ..., m)$

Para que $\hat{\theta}_k$ seja o melhor, então esse estimador deveria

- ser não tendencioso (exatidão) $\Rightarrow$ A média das estimativas de todas as amostras de tamanho n possíveis de serem retiradas da população é igual ao verdadeiro valor do parâmetro

$$E(\hat{\theta}_k) = \theta$$

- ter variância mínima (precisão) $\Rightarrow$ O melhor estimador irá produzir estimativas mais próximas entre si (idealmente próximas ao verdadeiro valor do parâmetro)

$$Var(\hat{\theta}_k) < Var(\hat{\theta}_j) \qquad \forall k \neq j$$

Tiro ao alvo

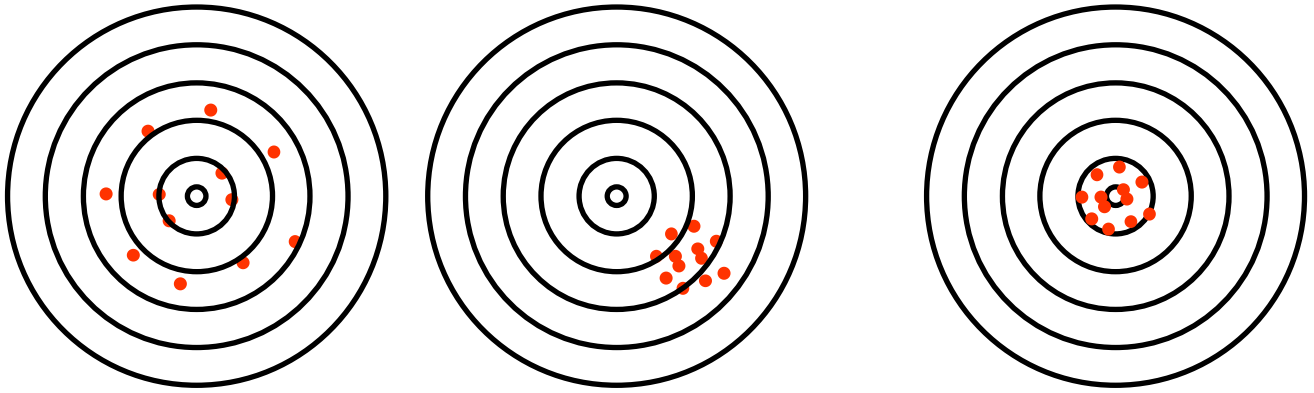

Exato
Impreciso

Inexato
Preciso

Exato
Preciso

Estimação Pontual de μ

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar μ.

- média populacional μ

Ex. amostra com $n = 5$ $\quad \{3{,}4;\ 4{,}5;\ 2{,}6;\ 3{,}8;\ 6{,}0\}$ $\quad \bar{X} = \frac{3,4 + 4,5 + 2,6 + 3,8 + 6,0}{5} = 4,06$

De que maneira os valores da amostra podem ser combinados a fim de se produzir uma "boa" estimativa de μ?

Como não há nenhuma razão para acreditar que um valor da amostra é mais importante do que o outro:

$$\hat{\mu} = \frac{\sum_{i=1}^{n} x_i}{n} = \bar{X} = \underbrace{\sum_{j=1}^{N} x_j FR(X = x_j)}_{\text{dados agrupados (v.a. discreta)}}$$

média amostral

Estimação Pontual de μ

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar μ.

- média populacional μ

Verificando a tendenciosidade de $\bar{X}$

$$E(\bar{X}) = E\left(\frac{X_1 + X_2 + \cdots + X_n}{n}\right) = \frac{E\left(X_1 + X_2 + \cdots + X_n\right)}{n}$$

$$= \frac{E\left(X_1\right) + E(X_2) + \cdots + E(X_n)}{n} = \frac{n\mu}{n} = \mu$$

estimador não tendencioso

Interpretação (teórica): se calculássemos a média dos $\bar{X}$ de todas amostras (de tamanho n) possíveis de serem obtidas, o resultado seria μ

Estimação Pontual de μ

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar μ.

- média populacional μ

Calculando a variância de $\bar{X}$ (avaliação de precisão)

$$Var(\bar{X}) = Var\left(\frac{X_1 + X_2 + \cdots + X_n}{n}\right) = \frac{Var\left(X_1 + X_2 + \cdots + X_n\right)}{n^2}$$

$$= \frac{Var(X_1) + Var(X_2) + \cdots + Var(X_n)}{n^2} = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

$\sigma^2 \quad + \quad \sigma^2 \quad + \ldots + \quad \sigma^2$

Se as amostras forem independentes, ou seja, se elas não guardarem nenhuma relação entre si.

Estimação Pontual de μ

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar μ.

- média populacional μ

$$\bar{X} = \frac{\sum_{i=1}^{n} x_i}{n} \qquad E(\bar{X}) = \mu \qquad \boxed{Var(\bar{X}) = \frac{\sigma^2}{n}}$$

A precisão da média amostral depende da variação original dos dados (σ^2) e do tamanho da amostra (n)

Quanto maior o tamanho da amostra (n), mais precisa será a estimativa de μ

Estimação Pontual de μ

- média populacional μ $\quad E(\bar{X}) = \mu \quad Var(\bar{X}) = \dfrac{\sigma^2}{n}$

Simulando-se $\bar{X}$ a partir de amostras de uma v.a. $X \sim N(\mu = 100, \sigma^2 = 25)$

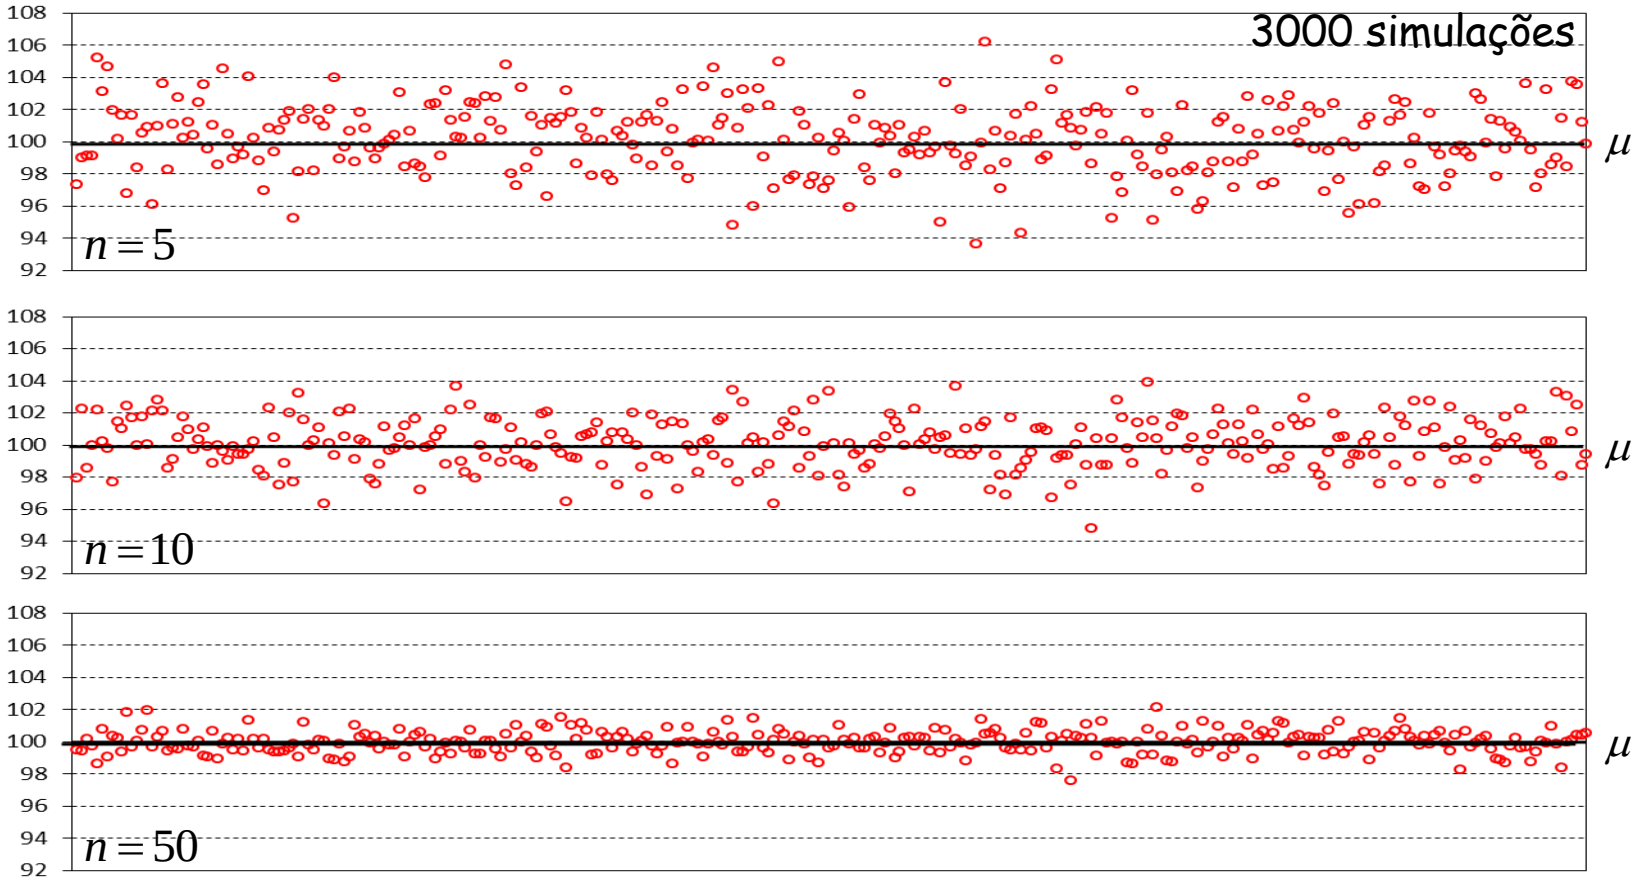

Estimação Pontual de σ^2

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar σ^2.

- variância populacional σ^2

De que maneira os valores da amostra podem ser combinados a fim de se produzir uma "boa" estimativa de σ^2?

Como não há nenhuma razão para acreditar que um valor da amostra é mais importante do que o outro e μ é desconhecido:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{X}\right)^2}{n}$$

Mas será um estimador tendencioso?

Estimação Pontual de σ^2

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar σ^2.

- variância populacional σ^2

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{X}\right)^2}{n}$$

$$\bar{X} = \frac{\sum_{i=1}^{n} X_i}{n} \Rightarrow \sum_{i=1}^{n} X_i = n\bar{X}$$

$$\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2 = \sum_{i=1}^{n}\left(X_i^2 - 2\bar{X}X_i + \bar{X}^2\right)$$

$$= \sum_{i=1}^{n} X_i^2 - 2\bar{X}\sum_{i=1}^{n} X_i + n\bar{X}^2$$

$$= \sum_{i=1}^{n} X_i^2 - 2n\bar{X}^2 + n\bar{X}^2$$

$$= \sum_{i=1}^{n} X_i^2 - n\bar{X}^2$$

Estimação Pontual de σ^2

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar σ^2.

- variância populacional σ^2

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{X}\right)^2}{n}$$

$$E\left(\hat{\sigma}^2\right) = E\left(\frac{\sum_{i=1}^{n} X_i^2 - n\bar{X}^2}{n}\right) = \frac{1}{n}E\left(\sum_{i=1}^{n} X_i^2\right) - E\left(\bar{X}^2\right)$$

$$= \frac{1}{n}\sum_{i=1}^{n} E\left(X_i^2\right) - E\left(\bar{X}^2\right)$$

$$Var(X_i) = \sigma^2 = E\left(X_i^2\right) - \left(E\left(X_i\right)\right)^2 = E\left(X_i^2\right) - \mu^2 \Rightarrow E\left(X_i^2\right) = \sigma^2 + \mu^2$$

Estimação Pontual de σ^2

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar σ^2.

- variância populacional σ^2

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{X}\right)^2}{n}$$

$$E\left(\hat{\sigma}^2\right) = E\left(\frac{\sum_{i=1}^{n} X_i^2 - n\bar{X}^2}{n}\right) = \frac{1}{n}E\left(\sum_{i=1}^{n} X_i^2\right) - E\left(\bar{X}^2\right)$$

$$= \frac{1}{n}\sum_{i=1}^{n} E\left(X_i^2\right) - E\left(\bar{X}^2\right)$$

$$Var(\bar{X}) = \frac{\sigma^2}{n} = E\left(\bar{X}^2\right) - \left(E\left(\bar{X}\right)\right)^2 = E\left(\bar{X}^2\right) - \mu^2 \Rightarrow E\left(\bar{X}^2\right) = \frac{\sigma^2}{n} + \mu^2$$

Estimação Pontual de σ^2

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar σ^2.

- variância populacional σ^2

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{X}\right)^2}{n}$$

$$E\left(\hat{\sigma}^2\right) = E\left(\frac{\sum_{i=1}^{n} X_i^2 - n\bar{X}^2}{n}\right) = \frac{1}{n}E\left(\sum_{i=1}^{n} X_i^2\right) - E\left(\bar{X}^2\right)$$

$$E\left(X_i^2\right) = \sigma^2 + \mu^2$$

$$E\left(\bar{X}^2\right) = \frac{\sigma^2}{n} + \mu^2$$

$$= \frac{1}{n}\sum_{i=1}^{n} E\left(X_i^2\right) - E\left(\bar{X}^2\right)$$

$$= \sigma^2 + \cancel{\mu^2} - \frac{\sigma^2}{n} - \cancel{\mu^2} = \frac{n\sigma^2 - \sigma^2}{n} = \boxed{\frac{n-1}{n}\sigma^2}$$

estimador tendencioso!

Estimação Pontual de σ^2

Seja X uma v.a. com distribuição qualquer com média (μ) e variância (σ^2) também desconhecidas. Retira-se uma amostra de tamanho n com a finalidade de se estimar σ^2.

- variância populacional σ^2

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{X}\right)^2}{n} \frac{n}{n-1}$$

$$s^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{X}\right)^2}{n-1}$$

variância amostral

$$E\left(s^2\right) = \sigma^2$$

estimador não tendencioso

Interpretação (teórica): se calculássemos a média dos s^2 de todas amostras (de tamanho n) possíveis de serem obtidas, o resultado seria σ^2

Curiosidade: $Var\left(s^2\right) = \frac{2\sigma^4}{n-1}$ (precisão aumenta com o tamanho da amostra!)

(ver Estimadores.xlsx)

Estimação Pontual de σ^2

- variância populacional σ^2 $\quad E(s^2) = \sigma^2$

Simulando-se s^2 a partir de amostras de uma v.a. $X \sim N(\mu = 100, \sigma^2 = 25)$

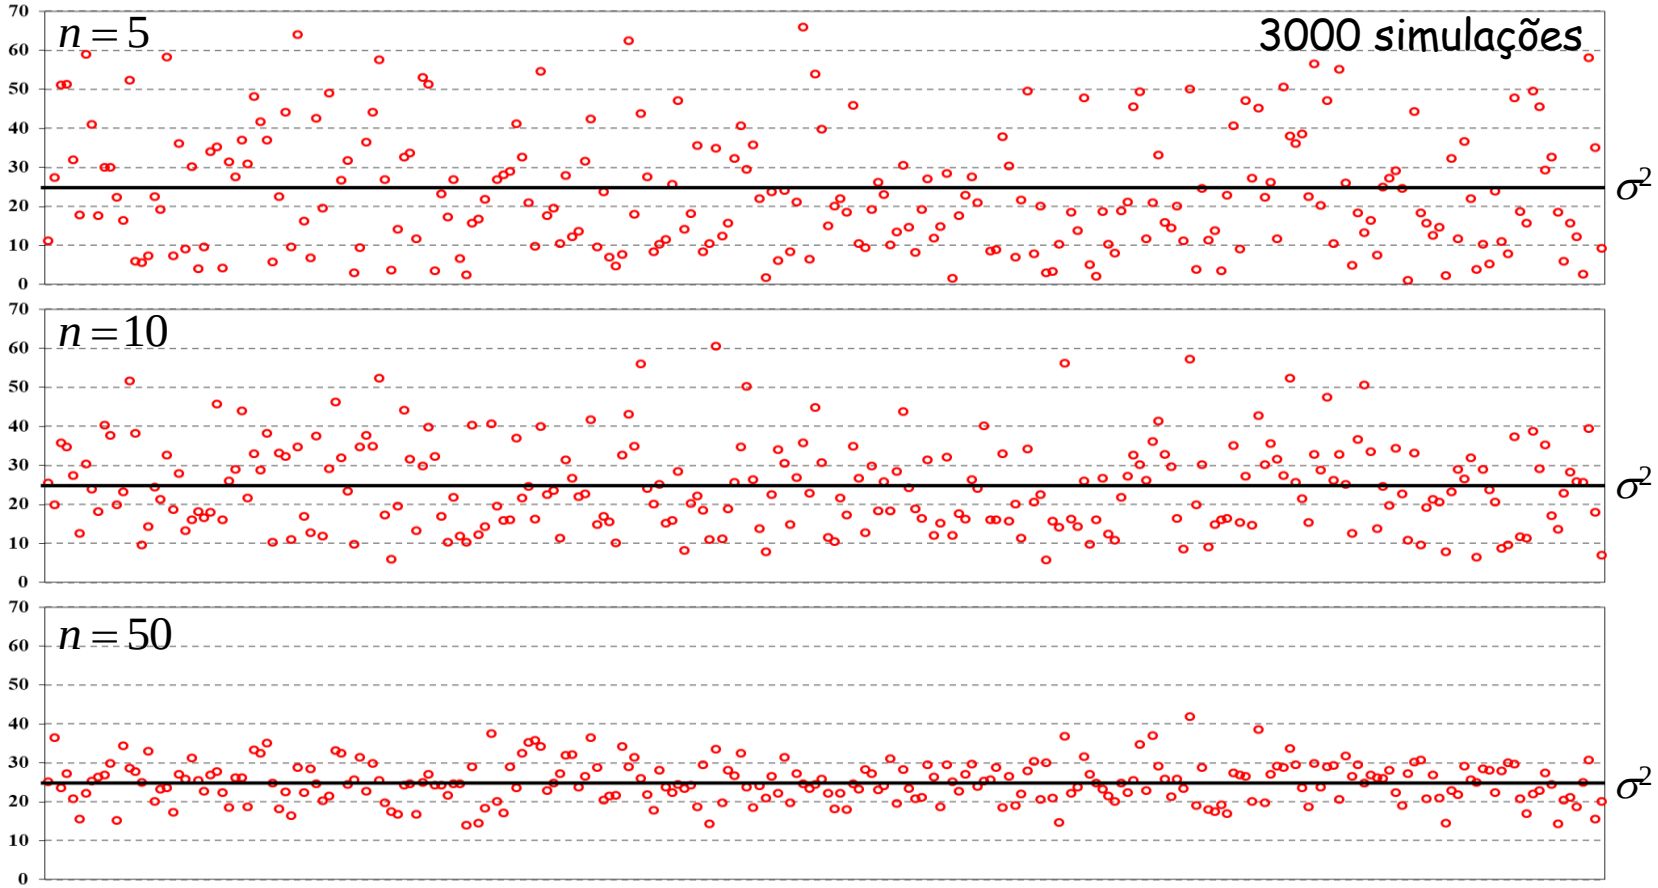

Estimação Pontual de p

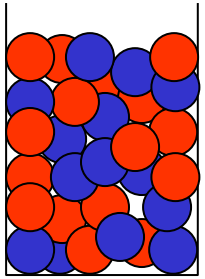

Numa urna, há N bolas, sendo K vermelhas e $N-K$ azuis. Assim, pode-se dizer que K/N representa a proporção p de bolas vermelhas na urna (que por sua vez, representa a probabilidade de se selecionar uma bola vermelha desta urna).

Mas se N e K são desconhecidos, como estimar p?

Considere que n bolas são escolhidas ao acaso (com reposição), definindo-se Y como o número de bolas vermelhas entre as n selecionadas, qual a distribuição de Y?

$Y \sim$ Binomial(n, p) $\qquad Y = \sum_{i=1}^{n} X_i \qquad X_i \sim$ Bernoulli $\quad p = P(X_i = 1) \quad \Leftrightarrow \quad P($sucesso$)$

Qual é o melhor estimador pontual de p?

$$\frac{Y}{n} = \hat{p}$$ Proporção Amostral

$$E(\hat{p}) = E\left(\frac{Y}{n}\right) = \frac{E(Y)}{n} = \frac{np}{n} = p$$ estimador não tendencioso

$$Var(\hat{p}) = Var\left(\frac{Y}{n}\right) = \frac{Var(Y)}{n^2} = \frac{npq}{n^2} = \frac{pq}{n}$$

Quanto maior o tamanho da amostra (n), mais precisa será a estimativa de p

Quanto mais p se aproxima de 0,5 (50%), menos precisa será sua estimativa

Estimação Pontual de p

- proporção populacional p $\quad E(\hat{p}) = p \quad Var(\hat{p}) = \frac{pq}{n}$

Simulando-se $\hat{p}$ a partir de amostras de uma v.a. $X \sim Binomial(n, p = 0,5)$

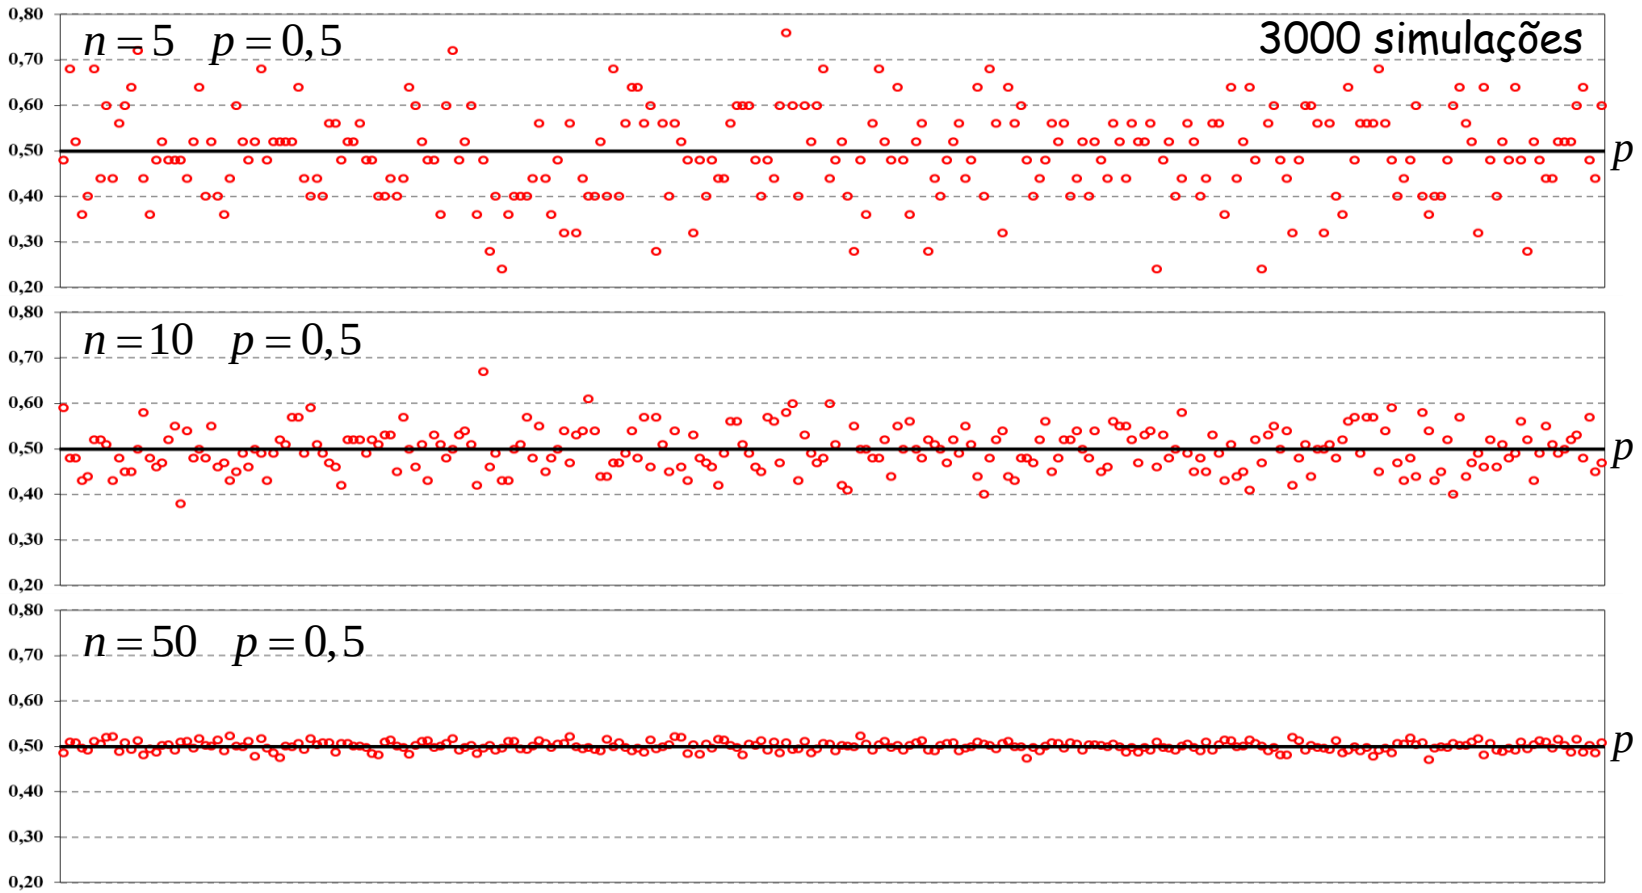

Estimação Pontual de p

- proporção populacional p $\quad E(\hat{p}) = p \quad Var(\hat{p}) = \dfrac{pq}{n}$

Simulando-se $\hat{p}$ a partir de amostras de uma v.a. $X \sim Binomial(n = 5, p)$

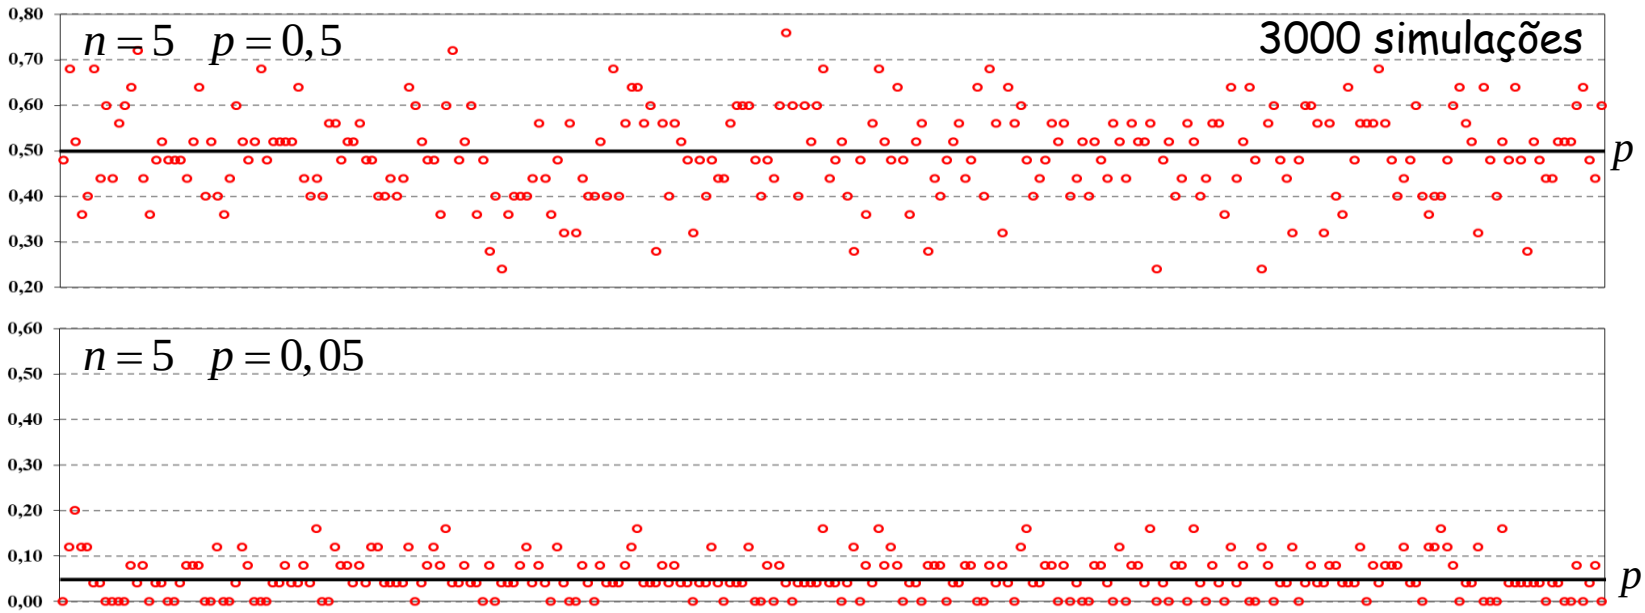

Estimação Pontual de μ e σ^2

Exemplo: uma amostra ($n = 12$) é retirada de uma população e os seguintes valores são observados: 0, 2, 3, 5, 2, 1, 2, 1, 3, 3, 4, 2. Calcule a média e variância amostrais.

distribuição amostral

Valor	Freq. Absoluta	Freq. Relativa
0	1	1/12
1	2	1/6
2	4	1/3
3	3	1/4
4	1	1/12
5	1	1/12
Total	12	1

- média amostral $\bar{X}$

$$\bar{X} = \frac{\sum_{i=1}^{n} x_i}{n}$$ (dados brutos)

$$\bar{X} = \frac{0+2+3+\ldots+2}{12} = \frac{7}{3}$$

$$\bar{X} = \frac{\sum_{j=1}^{N} x_j FA(X = x_j)}{n} = \sum_{j=1}^{N} x_j FR(X = x_j)$$ (dados agrupados)

$$\bar{X} = \frac{0*1+1*2+2*4+3*3+4*1+5*1}{12} = \frac{7}{3}$$ (usando FA)

$$\bar{X} = 0*\frac{1}{12}+1*\frac{1}{6}+2*\frac{1}{3}+3*\frac{1}{4}+4*\frac{1}{12}+5*\frac{1}{12} = \frac{7}{3}$$ (usando FR)

Estimação Pontual de μ e σ^2

Exemplo: uma amostra ($n = 12$) é retirada de uma população e os seguintes valores são observados: 0, 2, 3, 5, 2, 1, 2, 1, 3, 3, 4, 2. Calcule a média e variância amostrais.

distribuição amostral

Valor	Freq. Absoluta	Freq. Relativa
0	1	1/12
1	2	1/6
2	4	1/3
3	3	1/4
4	1	1/12
5	1	1/12
Total	12	1

- variância amostral s^2

$$\bar{X} = \frac{7}{3}$$

$$s^2 = \frac{\sum_{i=1}^{n}\left(x_i - \bar{X}\right)^2}{n-1} = \frac{\sum_{i=1}^{n} x_i^2 - n\bar{X}^2}{n-1} \qquad \text{(dados brutos)}$$

$$s^2 = \frac{(0-\frac{7}{3})^2 + (2-\frac{7}{3})^2 + \ldots + (2-\frac{7}{3})^2}{11} = \frac{(0^2 + 2^2 + \ldots + 2^2) - 12*\left(\frac{7}{3}\right)^2}{11} = 1{,}88$$

$$s^2 = \frac{\sum_{j=1}^{N}\left(x_j - \bar{X}\right)^2 FA(X = x_j)}{n-1} = \frac{\sum_{j=1}^{N} x_j^2 FA(X = x_j) - n\bar{X}^2}{n-1} \qquad \text{(dados agrupados)}$$

$$s^2 = \frac{(0-\frac{7}{3})^2 *1 + (1-\frac{7}{3})^2 *2 + \ldots + (5-\frac{7}{3})^2 *1}{11} = \frac{(0^2 *1 + 1^2 *2 + \ldots + 5^2 *1) - 12*\left(\frac{7}{3}\right)^2}{11} = 1{,}88$$

Estimação Pontual de μ, σ^2 e p

Observações:

- μ, σ^2 e p são parâmetros que representam a população e portanto são valores fixos sendo, em geral, desconhecidos

- $\bar{X}$, s^2 e $\hat{p}$ são estatísticas calculadas a partir da amostra e representam variáveis aleatórias (cada conjunto de amostras pode apresentar um valor diferente)

- Não confunda variância amostral (s^2) com variância da média amostral ($\mathrm{Var}(\bar{X})$)

- De modo geral, as amostras devem ser obtidas de modo independente uma das outras, ou seja, o valor de uma amostra não deve ter relação com o(s) valor(es) das outras amostras (exceção em estudos de séries temporais ou dados espaciais, onde estuda-se exatamente esta relação)

Utilização de amostras não independentes

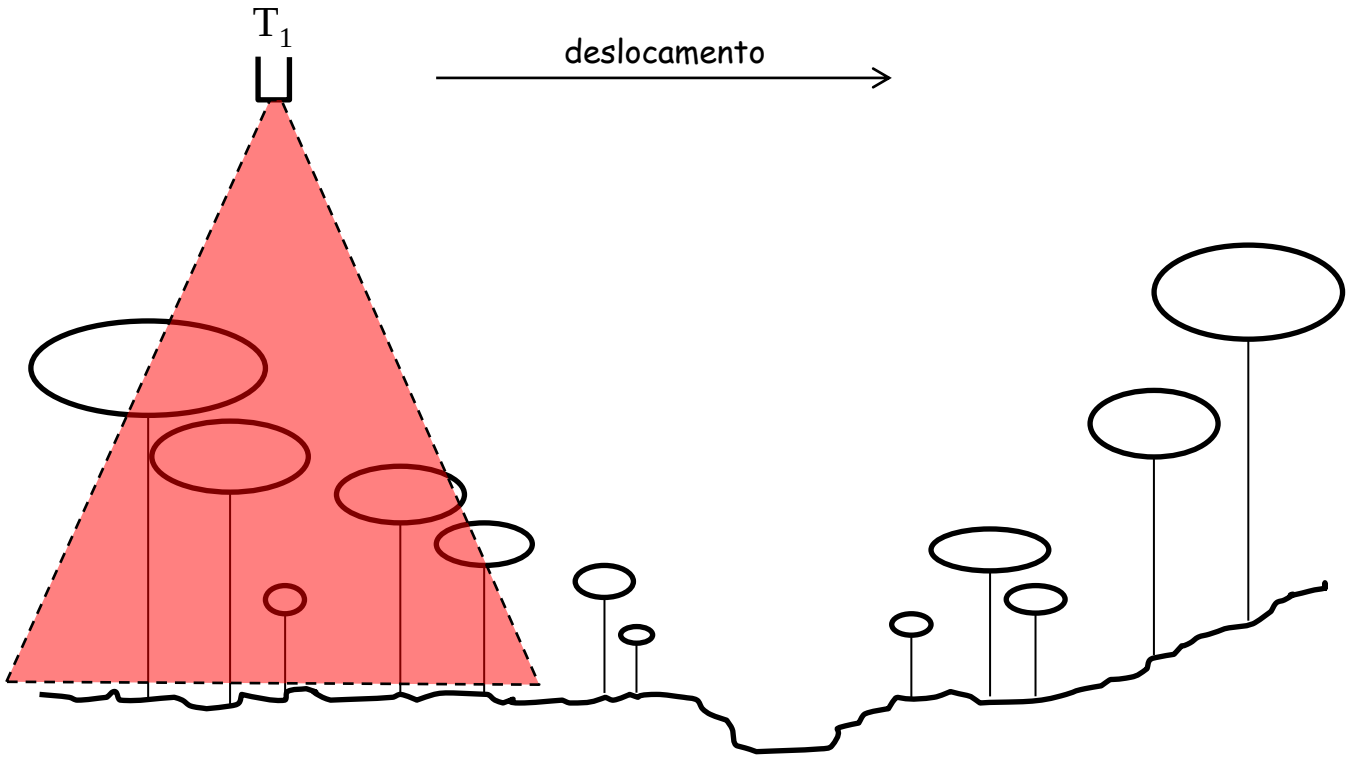

A resposta do sensor representa a integração das respostas de todos objetos que estão no campo de visada

Utilização de amostras não independentes

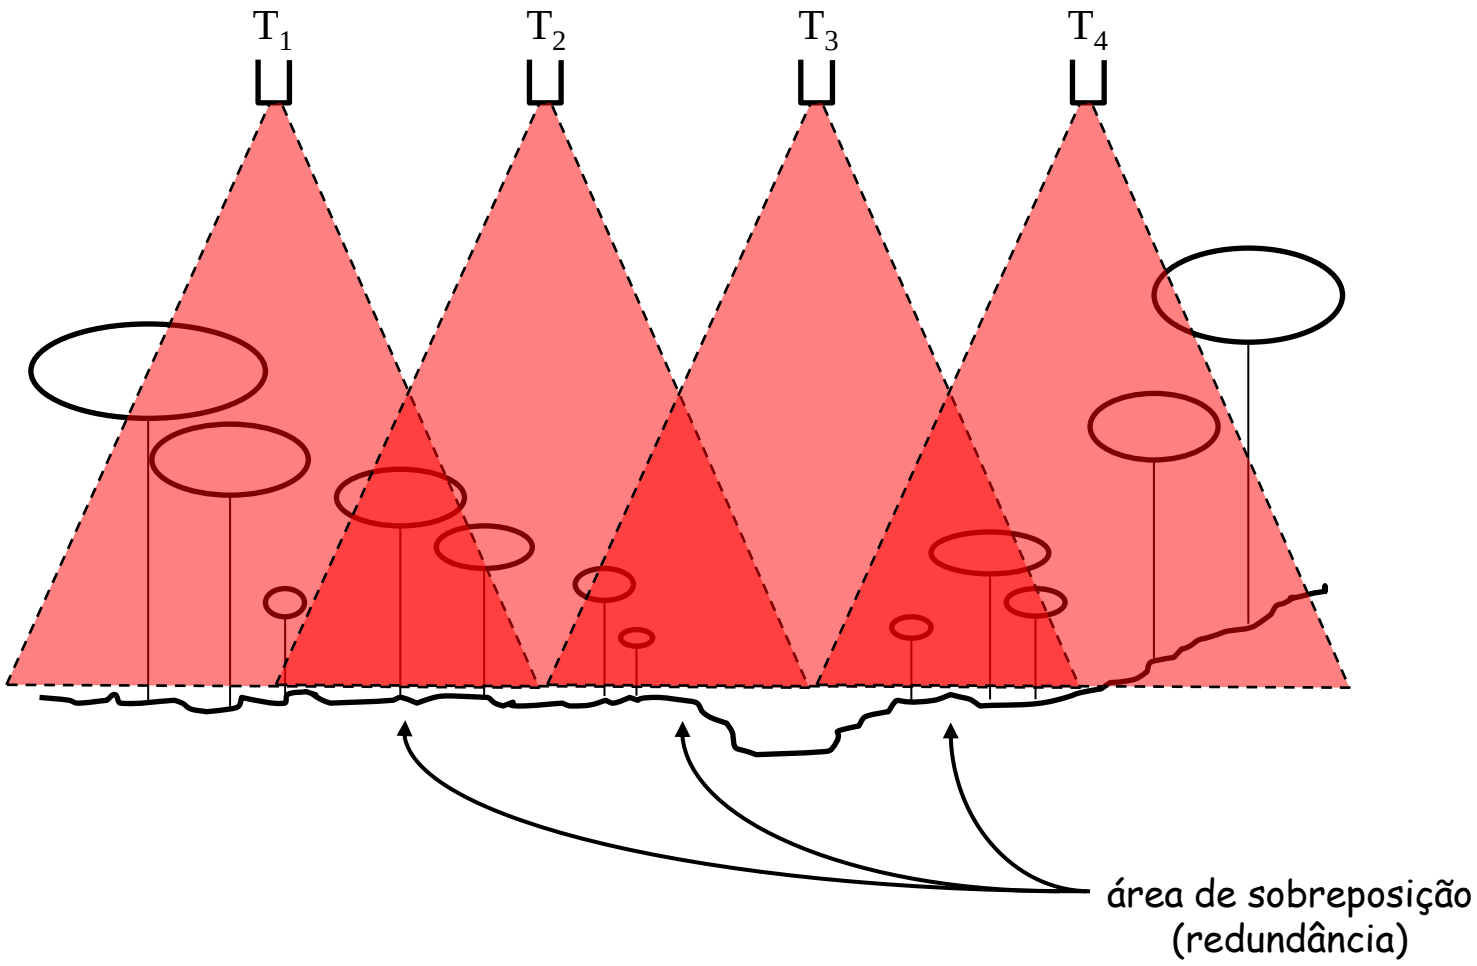

Utilização de amostras não independentes

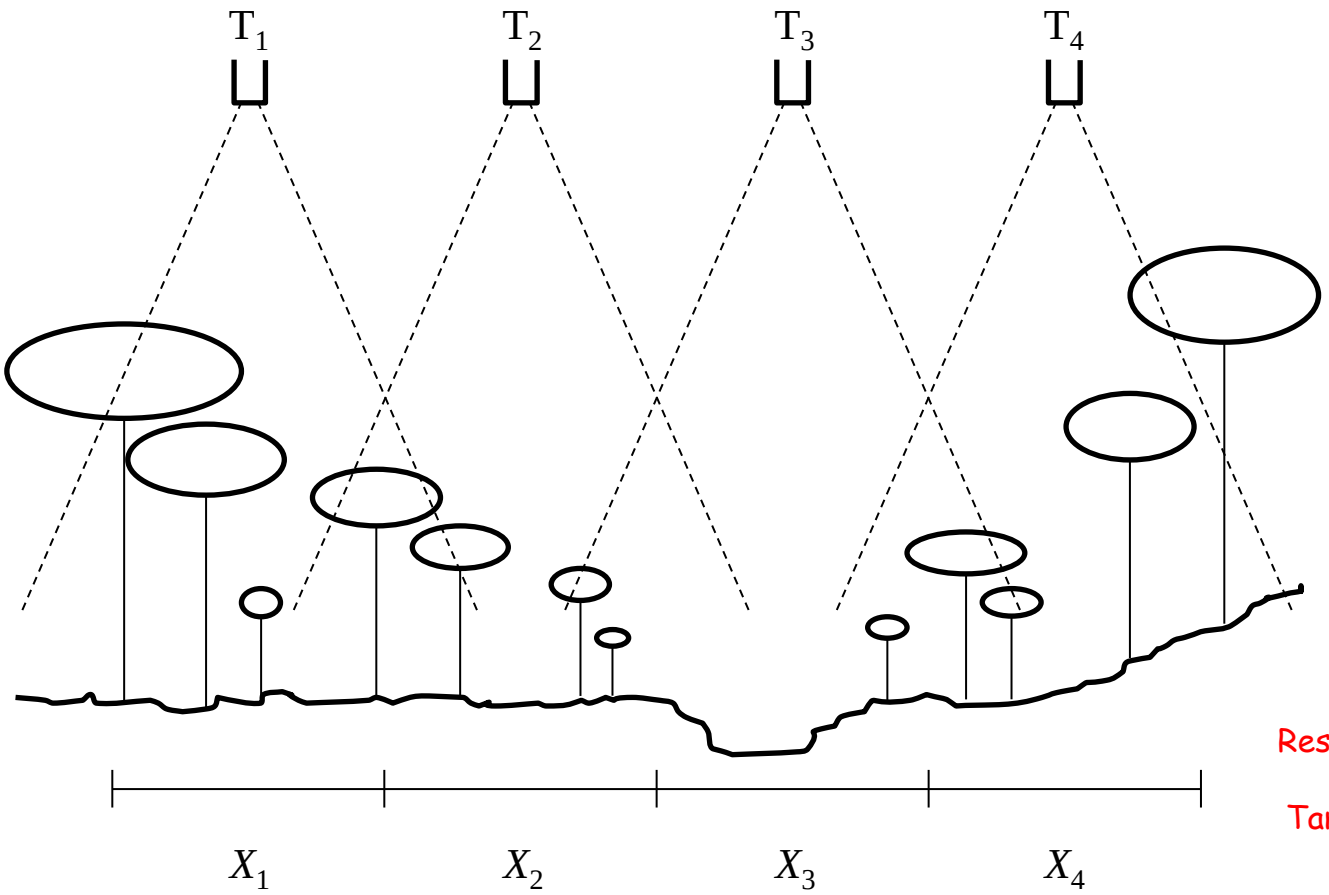

Resolução Espacial
≠
Tamanho do Pixel

X_i: valor que representa a resposta do sensor no tempo T_i (≡ elemento de resolução)

Note que estes valores não são independentes (devido a sobreposição)

Utilização de amostras não independentes

Suponha que X representa um conjunto de amostras independentes de uma v.a. qualquer obtidas numa determinada sequência (série temporal por exemplo)

X	X'	X''	X'''
9			
6			
2			
3	3,2		
6			
2			
6			
10			
6			
5			
7			
1			
7			
8			
5			

X', X'' e X''' resultam do cálculo de médias móveis (tamanho 3) aplicado sobre X

$$X'_i = 0,1X_{i-1} + 0,8X_i + 0,1X_{i+1}$$

Utilização de amostras não independentes

Suponha que X representa um conjunto de amostras independentes de uma v.a. qualquer obtidas numa determinada sequência (série temporal por exemplo)

X	X'	X''	X'''
9			
6	5,9		
2	2,5		
3	3,2		
6	5,3		
2	2,8		
6	6		
10	9,2		
6	6,3		
5	5,3		
7	6,2		
1	2,2		
7	6,5		
8	7,6		
5			

X', X'' e X''' resultam do cálculo de médias móveis (tamanho 3) aplicado sobre X

$$X'_i = 0,1X_{i-1} + 0,8X_i + 0,1X_{i+1}$$

$$X''_i = 0,2X_{i-1} + 0,6X_i + 0,2X_{i+1}$$

$$X'''_i = \left(X_{i-1} + X_i + X_{i+1}\right)/3$$

Utilização de amostras não independentes

Suponha que X representa um conjunto de amostras independentes de uma v.a. qualquer obtidas numa determinada sequência (série temporal por exemplo)

X	X'	X''	X'''
~~9~~			
6	5,9	5,8	5,67
2	2,5	3	3,67
3	3,2	3,4	3,67
6	5,3	4,6	3,67
2	2,8	3,6	4,67
6	6	6	6
10	9,2	8,4	7,33
6	6,3	6,6	7
5	5,3	5,6	6
7	6,2	5,4	4,33
1	2,2	3,4	5
7	6,5	6	5,33
8	7,6	7,2	6,67
~~5~~			

X', X'' e X''' resultam do cálculo de médias móveis (tamanho 3) aplicado sobre X

$$X'_i = 0,1X_{i-1} + 0,8X_i + 0,1X_{i+1}$$

$$X''_i = 0,2X_{i-1} + 0,6X_i + 0,2X_{i+1}$$

$$X'''_i = \left(X_{i-1} + X_i + X_{i+1}\right)/3$$

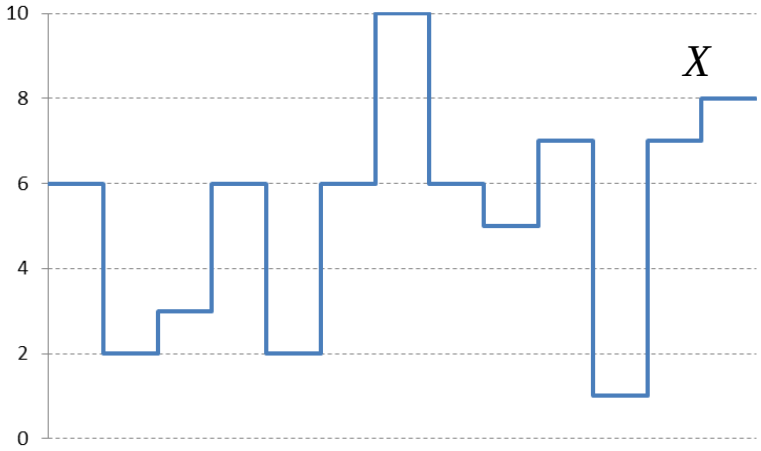

Utilização de amostras não independentes

Suponha que X representa um conjunto de amostras independentes de uma v.a. qualquer obtidas numa determinada sequência (série temporal por exemplo)

X	X'	X''	X'''
~~9~~			
6	5,9	5,8	5,67
2	2,5	3	3,67
3	3,2	3,4	3,67
6	5,3	4,6	3,67
2	2,8	3,6	4,67
6	6	6	6
10	9,2	8,4	7,33
6	6,3	6,6	7
5	5,3	5,6	6
7	6,2	5,4	4,33
1	2,2	3,4	5
7	6,5	6	5,33
8	7,6	7,2	6,67
~~5~~			

X', X'' e X''' resultam do cálculo de médias móveis (tamanho 3) aplicado sobre X

$$X'_i = 0,1X_{i-1} + 0,8X_i + 0,1X_{i+1}$$

$$X''_i = 0,2X_{i-1} + 0,6X_i + 0,2X_{i+1}$$

$$X'''_i = \left(X_{i-1} + X_i + X_{i+1}\right)/3$$

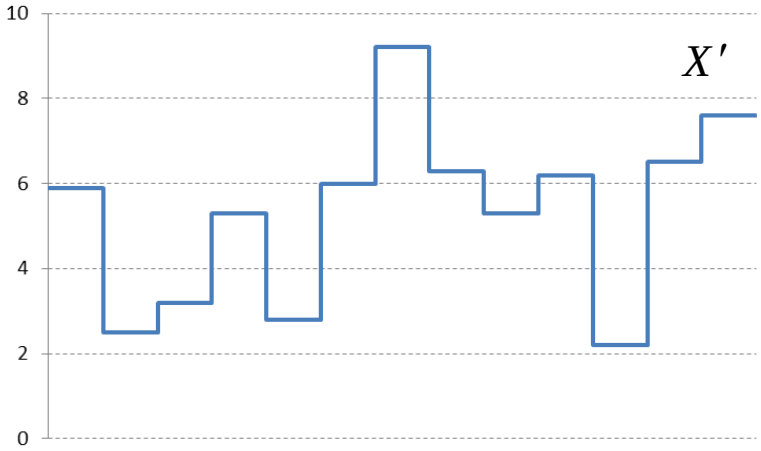

Utilização de amostras não independentes

Suponha que X representa um conjunto de amostras independentes de uma v.a. qualquer obtidas numa determinada sequência (série temporal por exemplo)

X	X'	X''	X'''
~~9~~			
6	5,9	5,8	5,67
2	2,5	3	3,67
3	3,2	3,4	3,67
6	5,3	4,6	3,67
2	2,8	3,6	4,67
6	6	6	6
10	9,2	8,4	7,33
6	6,3	6,6	7
5	5,3	5,6	6
7	6,2	5,4	4,33
1	2,2	3,4	5
7	6,5	6	5,33
8	7,6	7,2	6,67
~~5~~			

X', X'' e X''' resultam do cálculo de médias móveis (tamanho 3) aplicado sobre X

$$X'_i = 0,1X_{i-1} + 0,8X_i + 0,1X_{i+1}$$

$$X''_i = 0,2X_{i-1} + 0,6X_i + 0,2X_{i+1}$$

$$X'''_i = \left(X_{i-1} + X_i + X_{i+1}\right)/3$$

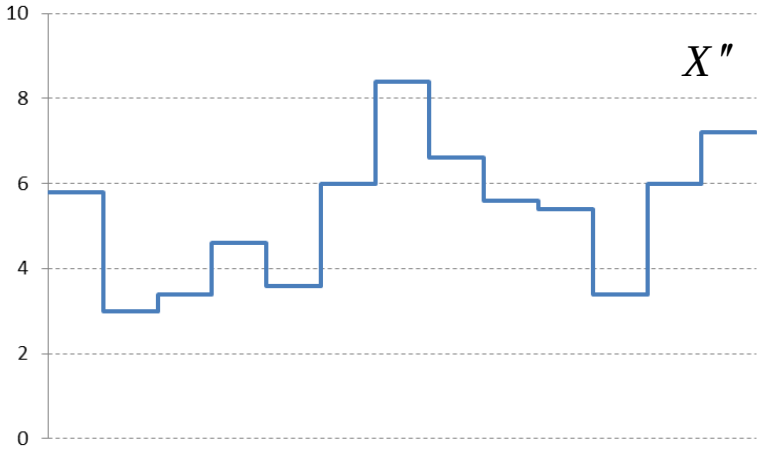

Utilização de amostras não independentes

Suponha que X representa um conjunto de amostras independentes de uma v.a. qualquer obtidas numa determinada sequência (série temporal por exemplo)

X	X'	X''	X'''
~~9~~			
6	5,9	5,8	5,67
2	2,5	3	3,67
3	3,2	3,4	3,67
6	5,3	4,6	3,67
2	2,8	3,6	4,67
6	6	6	6
10	9,2	8,4	7,33
6	6,3	6,6	7
5	5,3	5,6	6
7	6,2	5,4	4,33
1	2,2	3,4	5
7	6,5	6	5,33
8	7,6	7,2	6,67
~~5~~			

X', X'' e X''' resultam do cálculo de médias móveis (tamanho 3) aplicado sobre X

$$X'_i = 0,1X_{i-1} + 0,8X_i + 0,1X_{i+1}$$

$$X''_i = 0,2X_{i-1} + 0,6X_i + 0,2X_{i+1}$$

$$X'''_i = \left(X_{i-1} + X_i + X_{i+1}\right)/3$$

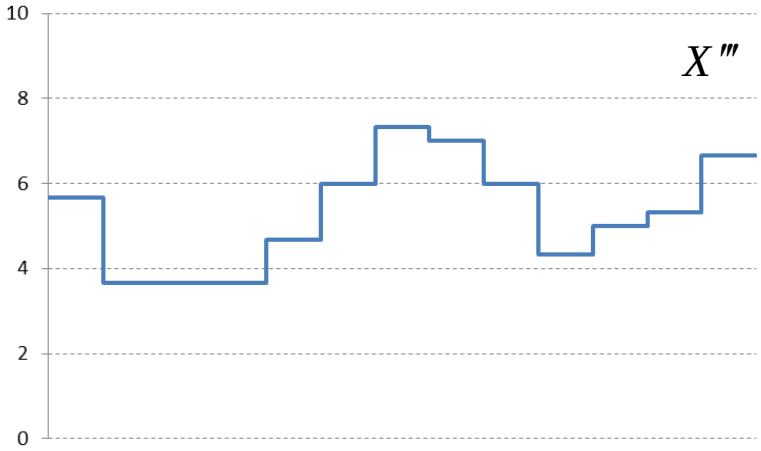

Utilização de amostras não independentes

Suponha que X representa um conjunto de amostras independentes de uma v.a. qualquer obtidas numa determinada sequência (série temporal por exemplo)

X	X'	X''	X'''
~~9~~			
6	5,9	5,8	5,67
2	2,5	3	3,67
3	3,2	3,4	3,67
6	5,3	4,6	3,67
2	2,8	3,6	4,67
6	6	6	6
10	9,2	8,4	7,33
6	6,3	6,6	7
5	5,3	5,6	6
7	6,2	5,4	4,33
1	2,2	3,4	5
7	6,5	6	5,33
8	7,6	7,2	6,67
~~5~~			

X', X'' e X''' resultam do cálculo de médias móveis (tamanho 3) aplicado sobre X

$$X'_i = 0,1X_{i-1} + 0,8X_i + 0,1X_{i+1}$$

$$X''_i = 0,2X_{i-1} + 0,6X_i + 0,2X_{i+1}$$

$$X'''_i = \left(X_{i-1} + X_i + X_{i+1}\right)/3$$

	$\bar{X}$	s^2
X	5,31	6,90
X'	5,31	4,39
X''	5,31	2,68
X'''	5,31	1,62

Conclusão: a utilização de amostras não independentes (autocorrelacionadas) afetam mais a estimação da variância do que a estimação da média

Distribuições amostrais

Um parâmetro pode ser estimado através de um único valor (estimador pontual)

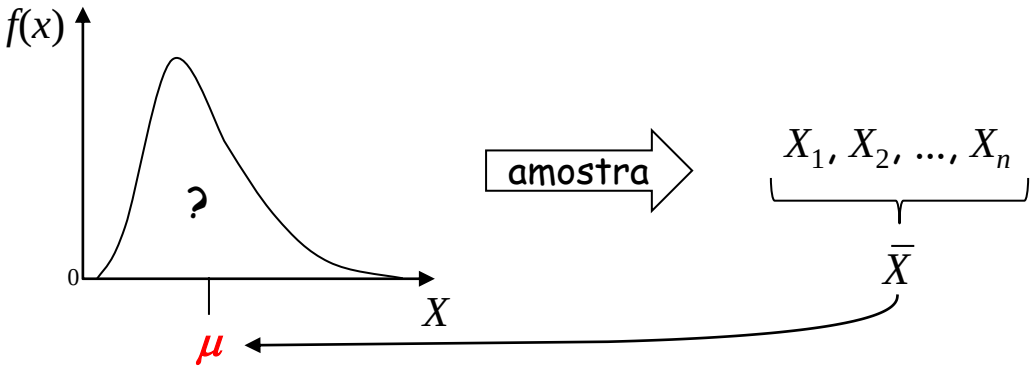

Se amostras de tamanho n fossem obtidas e para cada uma fosse calculada $\bar{X}$, poderíamos esperar que todas tivessem o mesmo valor? Muito pouco provável!

Como o estimador é uma v.a., então há, pelo menos teoricamente, uma distribuição associada a esse estimador.

Conhecer essas distribuições é fundamental para se entender o quão próximas ou distintas poderão ser as estimativas obtidas para as diferentes amostras, ou seja, entender qual a relação existente entre o estimador e o parâmetro que se deseja estimar.

Distribuição amostral relacionada com $\bar{X}$

$\{X_1, X_2, \ldots, X_n\}$ amostra aleatória

$X_i \sim ?(\mu, \sigma^2)$ distribuição desconhecida, μ desconhecido, mas σ^2 conhecido

$$\bar{X} = \frac{X_1 + X_2 + \cdots + X_n}{n}$$

Se $X_i \sim N(\mu, \sigma^2)$: $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ $E(\bar{X}) = \mu$ $Var(\bar{X}) = \frac{\sigma^2}{n}$

Se n for grande (ou seja, adotando-se o TLC):

$$\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$$

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)$$

é necessário conhecer σ^2

se X tiver distribuição Normal ou se n for grande (TLC válida)

Conclusão: sempre que precisarmos entender a relação entre $\bar{X}$ e μ, iremos usar a distribuição Normal Padrão, desde que σ^2 seja conhecida.

Distribuição amostral relacionada com s^2

$X = \{X_1, X_2, \cdots, X_n\}$ amostra aleatória

Se $X_i \sim N(\mu, \sigma^2)$ distribuição normal com μ e σ^2 desconhecidos

$$\frac{X_i - \mu}{\sigma} \sim N(0,1) \qquad \frac{(X_i - \mu)^2}{\sigma^2} \sim \chi^2_1$$

$$\frac{\sum_{i=1}^{n}(X_i - \mu)^2}{\sigma^2} \sim \chi^2_n \qquad \Rightarrow \text{precisaria conhecer } \mu \text{ !}$$

Substituindo-se μ por $\bar{X}$ tem-se que

$$\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{\sigma^2} \sim \chi^2_{n-1}$$ (perde-se 1 grau de liberdade)

mas $s^2 = \dfrac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1} \Rightarrow \sum_{i=1}^{n}(X_i - \bar{X})^2 = (n-1)s^2 \Rightarrow \boxed{\dfrac{(n-1)s^2}{\sigma^2} \sim \chi^2_{n-1}}$

Conclusão: sempre que precisarmos entender a relação entre s^2 e σ^2, iremos usar a distribuição Qui-quadrado (neste caso, é necessário que $X \sim Normal$).

Graus de liberdade

De modo geral, pode-se entender "grau de liberdade" como o número de valores que, no final de um cálculo de uma estatística, estão "livres para variarem", ou seja, que têm o comportamento de variáveis aleatórias.

Por exemplo: deseja-se avaliar os desvios em torno da média a partir de uma amostra de 3 valores retirados de uma população normalmente distribuída.

$X \sim N\left(\mu, \sigma^2\right)$ Amostra: $\left\{X_1 - \mu, X_2 - \mu, X_3 - \mu\right\}$ (μ é conhecida)

Quais são os valores possíveis de serem obtidos nesta amostra?

R: Neste caso, posso escolher "livremente" quaisquer 3 valores entre -∞ e +∞

-3,5 0,5 100,9

Graus de liberdade

Agora, se μ é desconhecido e o substituímos por $\bar{X}$ ...

Amostra: $\left\{X_1 - \bar{X}, X_2 - \bar{X}, X_3 - \bar{X}\right\}$

Como $\bar{X} = \left(X_1 + X_2 + X_3\right)/3$ então $\sum_{i=1}^{3}\left(X_i - \bar{X}\right) = 0$

Assim, ao se escolher os dois primeiros valores, o terceiro é necessariamente conhecido. Neste caso, perde-se 1 grau de liberdade

$$-1,5 + 0,1 + (X_3 - \bar{X}) = 0$$

-1,5 0,1 1,4

As perdas de graus de liberdade acontecem sempre que um parâmetro é substituído por seu estimador

Distribuição amostral relacionada com $\bar{X}$

$X = \{X_1, X_2, \cdots, X_n\}$ amostra aleatória

Se $X_i \sim N(\mu, \sigma^2)$ distribuição normal com μ e σ^2 desconhecidos

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)$$

Lembrete: $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2_{n-1}$$

$$\frac{\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{(n-1)s^2}{(n-1)\sigma^2}}} = \frac{\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}}{\frac{s}{\sigma}} = \boxed{\frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim t_{n-1}}$$

Se n é grande ($n > 100$):

$$\frac{\bar{X} - \mu}{\frac{s}{\sqrt{n}}} \sim N(0,1)$$

Conclusão: sempre que precisarmos entender a relação entre $\bar{X}$ e μ mas σ^2 for desconhecida, iremos usar a distribuição *t-Student* (neste caso, é necessário que $X \sim Normal$). Se n for grande, pode-se usar a Normal Padrão.

Distribuição amostral relacionada com $\bar{X}_1$ e $\bar{X}_2$

$$X_1 = \{X_{1,1}, X_{1,2}, \cdots, X_{1,n_1}\}$$

$$X_2 = \{X_{2,1}, X_{2,2}, \cdots, X_{2,n_2}\}$$

2 amostras aleatórias independentes

$X_{1,i} \sim N(\mu_1, \sigma_1^2)$ $\quad X_{2,i} \sim N(\mu_2, \sigma_2^2)$ $\quad \mu_j$ desconhecidas, mas σ_j^2 conhecidas

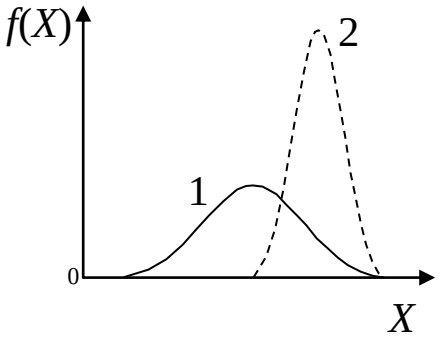

$$\bar{X}_1 \sim N(\mu_1, \frac{\sigma_1^2}{n_1})$$

$$\bar{X}_2 \sim N(\mu_2, \frac{\sigma_2^2}{n_2})$$

Quão próximos estão μ_1 e μ_2 ?

$$\bar{X}_1 - \bar{X}_2 \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$$

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$$

Normal Padrão

Distribuição amostral relacionada com $\bar{X}_1$ e $\bar{X}_2$

$$X_1 = \left\{ X_{1,1}, X_{1,2}, \cdots, X_{1,n_1} \right\}$$

$$X_2 = \left\{ X_{2,1}, X_{2,2}, \cdots, X_{2,n_2} \right\}$$

2 amostras aleatórias independentes

$X_{1,i} \sim N(\mu_1, \sigma_1^2)$ $\quad X_{2,i} \sim N(\mu_2, \sigma_2^2)$ $\quad \mu_j$ e σ_j^2 desconhecidas

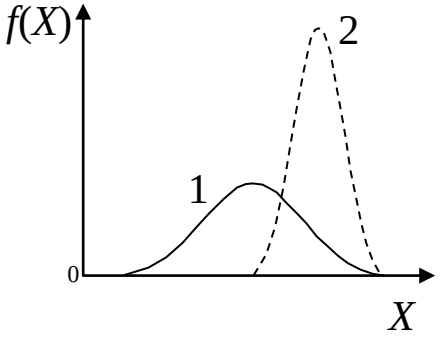

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$$

$$\frac{(n_1 - 1)s_1^2}{\sigma_1^2} + \frac{(n_2 - 1)s_2^2}{\sigma_2^2} \sim \chi^2_{n_1+n_2-2}$$

$$\frac{\dfrac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\dfrac{\sigma_1^2}{n_1} + \dfrac{\sigma_2^2}{n_2}}}}{\sqrt{\dfrac{\dfrac{(n_1 - 1)s_1^2}{\sigma_1^2} + \dfrac{(n_2 - 1)s_2^2}{\sigma_2^2}}{n_1 + n_2 - 2}}} \sim t_{n_1+n_2-2}$$

a princípio sem solução pois σ_1^2 e σ_2^2 são desconhecidos!

Distribuição amostral relacionada com $\bar{X}_1$ e $\bar{X}_2$

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \Bigg/ \sqrt{\frac{\frac{(n_1-1)s_1^2}{\sigma_1^2} + \frac{(n_2-1)s_2^2}{\sigma_2^2}}{n_1+n_2-2}} \sim t_{n_1+n_2-2}$$

(fazendo $\sigma_1^2 = \sigma_2^2 \Rightarrow \sigma^2$)

abordagem homocedástica

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\cancel{\sigma}\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \Bigg/ \frac{1}{\cancel{\sigma}}\sqrt{\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}} \sim t_{n_1+n_2-2}$$

rearranjando os termos...

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}}\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

Distribuição amostral relacionada com $\bar{X}_1$ e $\bar{X}_2$

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$$

(considerando $\sigma_1^2 \neq \sigma_2^2$)

abordagem heterocedástica

$$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \sim t_g$$

$$g \approx \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 - 1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2 - 1}}$$

Importante: a seleção de qual abordagem (homo ou heterocedástica) deve ser adotada é feita verificando-se previamente se as variâncias populacionais podem ou não ser consideradas iguais (teste de hipóteses)

Distribuição amostral relacionada com s_1^2 e s_2^2

$$X_1 = \left\{ X_{1,1}, X_{1,2}, \cdots, X_{1,n_1} \right\}$$

$$X_2 = \left\{ X_{2,1}, X_{2,2}, \cdots, X_{2,n_2} \right\}$$

2 amostras aleatórias independentes

$X_{1,i} \sim N(\mu_1, \sigma_1^2)$ $\quad X_{2,i} \sim N(\mu_2, \sigma_2^2)$ $\quad \mu_j$ e σ_j^2 desconhecidas

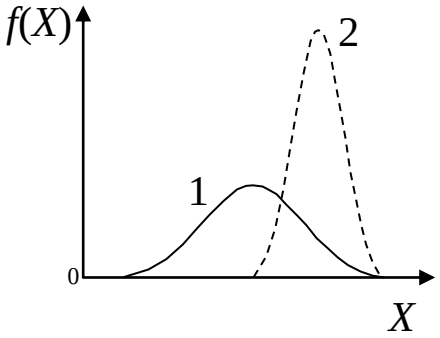

Quão semelhantes são σ_1^2 e σ_2^2?

$$\frac{(n_1-1)s_1^2}{\sigma_1^2} \sim \chi^2_{n_1-1} \qquad \frac{(n_2-1)s_2^2}{\sigma_2^2} \sim \chi^2_{n_2-1}$$

$$\frac{\dfrac{(n_1-1)s_1^2}{\sigma_1^2}}{\dfrac{n_1-1}{\dfrac{(n_2-1)s_2^2}{\sigma_2^2}}} \sim F_{n_1-1,n_2-1}$$

$$\frac{\cancel{(n_1-1)}s_1^2}{\cancel{(n_1-1)}\sigma_1^2} \Big/ \frac{\cancel{(n_2-1)}s_2^2}{\cancel{(n_2-1)}\sigma_2^2} = \frac{s_1^2}{\sigma_1^2}\frac{\sigma_2^2}{s_2^2}$$

$$\frac{s_1^2\sigma_2^2}{s_2^2\sigma_1^2} \sim F_{n_1-1\,n_2-1}$$

Distribuição amostral relacionada com $\hat{p}$

$Y \sim$ Binomial(n, p) $\quad Y = \sum_{i=1}^{n} X_i \quad X_i \sim$ Bernoulli $\quad p = P(X_i = 1) \Leftrightarrow P($sucesso$)$

$\frac{Y}{n} = \hat{p}$ Proporção Amostral $\quad E(\hat{p}) = p \quad Var(\hat{p}) = \frac{pq}{n}$

Qual a distribuição de $\hat{p}$?

Se n for grande (ou seja, adotando-se o TLC):

$$\hat{p} \sim N(p, \frac{pq}{n})$$

$$\frac{\hat{p} - p}{\sqrt{\frac{pq}{n}}} \sim N(0,1)$$

Distribuição amostral relacionada com $\hat{p}_1$ e $\hat{p}_2$

$Y_1 \sim \text{Binomial}(n_1, p_1)$ $\qquad$ $Y_2 \sim \text{Binomial}(n_2, p_2)$

$$\frac{Y_1}{n_1} = \hat{p}_1 \qquad E(\hat{p}_1) = p_1 \qquad Var(\hat{p}_1) = \frac{p_1 q_1}{n_1}$$

$$\frac{Y_2}{n_2} = \hat{p}_2 \qquad E(\hat{p}_2) = p_2 \qquad Var(\hat{p}_2) = \frac{p_2 q_2}{n_2}$$

Se n_1 e n_2 forem grandes (ou seja, adotando-se o TLC):

$$\hat{p}_1 \sim N(p_1, \frac{p_1 q_1}{n_1}) \qquad \hat{p}_2 \sim N(p_2, \frac{p_2 q_2}{n_2})$$

$$\frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}} \sim N(0,1)$$

Distribuições amostrais (Resumo)

para $\bar{X}$ $\begin{cases} N(0,1) & \text{se } \sigma^2 \text{ é conhecida} \\ t_{n-1} & \text{se } \sigma^2 \text{ é desconhecida} \end{cases}$

para s^2 $\left\{ \chi^2_{n-1} \right.$

para $\bar{X}_1 - \bar{X}_2$ $\begin{cases} N(0,1) & \text{se } \sigma_1^2 \text{ e } \sigma_2^2 \text{ são conhecidas} \\ t_{n_1+n_2-2} & \text{se } \sigma_1^2 \text{ e } \sigma_2^2 \text{ são desconhecidas, mas } \sigma_1^2 = \sigma_2^2 \\ t_g & \text{se } \sigma_1^2 \text{ e } \sigma_2^2 \text{ são desconhecidas, mas } \sigma_1^2 \neq \sigma_2^2 \end{cases}$

para $\dfrac{s_1^2}{s_2^2}$ $\left\{ F_{n_1-1,n_2-1} \right.$

para $\hat{p}$ $\left\{ N(0,1) \right.$

para $\hat{p}_1 - \hat{p}_2$ $\left\{ N(0,1) \right.$