
Estatística: Aplicação ao Sensoriamento Remoto

SER 204

Teoria da amostragem

Camilo Daleles Rennó

camilo.renno@inpe.br

acesso do conteúdo do curso em <https://cdrenno.github.io/Estatistica/>

Algumas Considerações...

É importante ter consciência de que dominar as técnicas estatísticas não é suficiente para garantir o sucesso de uma análise, ou seja, conseguir chegar a conclusões “interessantes”.

De forma geral, para que as análises estatísticas sejam válidas, as amostras devem representar a população, ou seja, a menos que discrepâncias ocorram devido ao acaso, as amostras devem reproduzir as mesmas características da população considerando a variável estudada.

É fundamental que as amostras sejam obtidas por processos adequados de modo a evitar que erros grosseiros possam comprometer a análise dos dados.

Algumas Considerações...

Em muitos casos, é bastante tentador que as observações mais convenientes sejam as selecionadas para compor uma amostra ou então aplicar algum tipo de critério (ou julgamento) no momento dessa seleção.

Nesses casos, pode-se introduzir algum tipo de tendência que poderá causar uma super ou subestimativa dos parâmetros de interesse. A identificação (e descrição) desta tendência pode ser difícil (ou impossível) de ser feita após a coleta dessas amostras.

Algumas vezes, há sim um propósito explícito na escolha da amostra com o objetivo de se escolher poucas amostras representativas da população.

No entanto, de modo geral, a seleção das amostras é feita através de algum processo aleatório, de modo que qualquer elemento da população tenha igual chance de ser escolhido para compor a amostra.

Censo ou Amostragem?


Por que fazer **Censo**?

- a população é pequena ou amostragem “ideal” é quase tão grande quanto a população
- necessita-se de uma precisão completa (não é permitido nenhum erro)
- os dados de toda população já se encontram disponíveis

Por que fazer **Amostragem**?

- a população é infinita (ou muito grande)
- os custos de obtenção das medidas são elevados (análises muito caras)
- o tempo para caracterização da população é muito longo
- deseja-se aumentar a representatividade, amostrando-se diferentes populações
- necessita-se melhorar a precisão das medidas (mais cuidado na obtenção dos dados)
- a obtenção das medidas requer a destruição das amostras (p. ex: biomassa)

Amostragem



Toda amostragem requer **planejamento**

- a) O que quero caracterizar neste estudo?
algum parâmetro específico (média, variância, etc),
distribuição espacial e/ou variação temporal é importante?
- b) Qual é a unidade amostral apropriada para o estudo?
quem é o elemento da população (unidade amostral)?
- c) Como estas amostras devem ser coletadas?
há variabilidade espacial e temporal?
quais fatores podem influenciar nos resultados?
- d) Quantas amostras são necessárias?
qual é a precisão exigida?
quanto tempo e recurso disponho?

Unidade Amostral

A unidade amostral representa a menor entidade identificada na população e é considerada o objeto de estudo.


Ela constitui o elemento da população na qual são coletadas as medidas ou informações (qualitativas ou quantitativas) que serão analisadas.

Em estudos na área de Sensoriamento Remoto e Geoprocessamento, podem ser representados por:


- pontos
- objetos (polígonos ou linhas)

Unidade Amostral


Pontos



posição no espaço
(p.ex. ponto num lago)



indivíduo da população
(p.ex. árvore numa floresta)




pixel da imagem ou grade


- sorteio aleatório é facilitado
- em coletas em campo, a localização precisa do ponto sorteado pode ser difícil
- pode induzir a erros em regiões heterogêneas

Unidade Amostral


Objetos




região no espaço
(p.ex. talhão agrícola)



linha
(p.ex. trecho de rio)



indivíduos da população
(p.ex. transecto)



segmento

- deve representar áreas homogêneas (deve-se evitar áreas de transição)
- em coletas de campo, minimiza problemas de posicionamento quando informação contextual é considerada
- mesmo podendo conter muitos valores medidos, deve ser contabilizado como apenas uma observação e portanto deve-se adotar uma medida representativa (total, média, mediana, etc)

Tipos de Amostragem

Como amostrar?

amostragem probabilística X não probabilística

Amostragem probabilística:

cada elemento da população tem uma probabilidade (não nula) de ser escolhido
em geral, todo elemento tem a mesma probabilidade de ser escolhido



Neste tipo de amostragem, todos os elementos devem ser previamente identificados e a escolha é feita por sorteio realizado posteriormente e de forma independente

Tipos de Amostragem

Como amostrar?

amostragem probabilística X não probabilística

Amostragem probabilística:

cada elemento da população tem uma probabilidade (não nula) de ser escolhido
em geral, todo elemento tem a mesma probabilidade de ser escolhido




Tipos de Amostragem

Como amostrar?

amostragem probabilística X não probabilística

Amostragem probabilística:

cada elemento da população tem uma probabilidade (não nula) de ser escolhido
em geral, todo elemento tem a mesma probabilidade de ser escolhido



Tipos de Amostragem

Como amostrar?

amostragem probabilística X não probabilística

Amostragem não probabilística:

escolha a esmo (rotulagem inviável ou impossível)

populações muito grandes (ex: estudo sobre a variabilidade no DAP em talhões de reflorestamento de eucalipto)

populações dinâmicas (ex: estudo sobre qualidade de água num rio)

amostragem restrita aos elementos que se tem acesso (ex: estudo sobre ocorrência de focos de dengue em casas de veraneio)

amostragem intencional ou por julgamento (ex: estudo sobre diversidade florística de plantas com DAP maior que 30cm dentro de um transecto)


voluntários (ex: estudo sobre a eficácia de uma nova vacina contra febre amarela)

OBS: escolha a esmo é a abordagem que mais se assemelha à amostragem probabilística desde que se garanta que não haja nenhum tipo de influência na seleção das amostras


Tipos de Amostragem

Do ponto de vista estatístico, a amostragem probabilística é a ideal

Sempre que uma abordagem não probabilística for adotada, deve-se explicitá-la no trabalho de pesquisa



OLI/Landsat R6G5B4



Classificação



Numa análise sobre a qualidade da classificação, deve-se explicitar que as regiões marcadas como “Não Classificado” e “Não Observado” não serão consideradas na avaliação

Nesse caso, a amostragem não é tipicamente probabilística pois os pixels pertencentes a essas classes não podem ser sorteados (probabilidade nula)

Desenho amostral (*Sampling Design*)

O Desenho Amostral define como as amostras serão coletadas.

A escolha da melhor estratégia dependerá:


- da facilidade e praticidade de implementação
- dos custos para obtenção das amostras
- da heterogeneidade espacial dos dados (distribuição espacial)

Decisões chaves:

- usar abordagem simples ou sistemática?
- usar ou não uma amostragem estratificada?
- selecionar amostras isoladas ou em conglomerados (*clusters*)?

Amostragem Aleatória Simples

Nesta abordagem, a escolha de uma amostra é feita de modo totalmente independente das outras amostras já selecionadas



etapas:

- rotular cada elemento com um código único
- sortear aleatoriamente n códigos (usando-se geradores de números aleatórios)
- identificar os elementos com os códigos selecionados

OBS: método simples

rotulação dos elementos pode ser dispendiosa

pressupõe população homogênea

não garante representatividade pois alguns


grupos (mais raros) podem não ser sorteados

Amostragem Aleatória Simples

Em trabalhos de campo, muitas vezes não é possível fazer a identificação prévia dos elementos

Nesse caso, é usual fazer a **escolha a esmo** dos elementos amostrados usando artifícios que garantam a escolha imparcial



Exemplo: numa floresta, deseja-se amostrar 10 árvores



- numa trilha, caminha-se **x metros**
- caminha-se **y metros** numa determinada **direção**
- escolhe-se a árvore mais próxima
- faz-se as medições necessárias
- retorna-se ao ponto inicial
- repete-se o procedimento até selecionar-se as 10 árvores

Amostragem Sistemática


Se os elementos da população já se encontram ordenados segundo algum critério, pode-se selecionar um elemento qualquer e escolher um "passo" que definirá qual será o próximo elemento escolhido.



etapas:


- definir o passo (ou os passos em x e em y)
- escolher aleatoriamente um elemento
- com base nesse elemento, identificar os demais elementos de acordo com o passo pré-definido

OBS: amostra-se uniformemente todo o espaço
pode-se não conseguir o valor exato de amostras pretendidas
desaconselhado para ordenações periódicas ou com feições dispostas na horizontal e/ou vertical



Amostragem Sistemática Não Alinhada

A ideia é semelhante da amostragem sistemática mas, nesse caso, tenta-se aleatorizar os passos de modo a desalinhar as amostras sorteadas.




etapas:


- definir o passo (ou os passos em x e em y)
- escolher aleatoriamente um elemento
- com base nesse elemento, identificar os elementos da mesma linha e mesma coluna de acordo com o passo pré-definido
- desalinhar aleatoriamente esses elementos
- utilizar esses novos posicionamentos para identificar os demais elementos

Amostragem em Conglomerados (*Cluster*)

Nesta abordagem, a amostra é formada por um grupo de elementos próximos (cluster)



raio r



janela 3x3


etapas:

- definir critério de proximidade (raio ou janela)
- sortear aleatoriamente n posições
- identificar os elementos que atendam o critério de proximidade

OBS: simplifica a coleta de dados das amostras
cada elemento do conglomerado constitui uma unidade amostral
diminui os custos da amostragem
pode reduzir a precisão na estimação devido a autocorrelação espacial

Amostragem Estratificada

A estratificação é a divisão da área de estudo em regiões segundo algum critério (mapas pré-existentes ou regiões geográficas)



Mas para que estratificar?

- os estratos representam regiões de interesse no estudo
p.ex., estimar a área desmatada por Estado ou município
- deseja-se melhorar a precisão nas estimativas obtidas em cada estrato
como quanto maior heterogeneidade, maior incerteza na estimativa. Pode-se assim concentrar a amostragens nos estratos com maior variabilidade
- deseja-se aumentar a representatividade da amostra coletada na área de estudo
estratos raros podem não estar representados adequadamente numa amostragem totalmente aleatória

Dentro de cada estrato, pode-se adotar a Amostragem Aleatória Simples, Sistemática ou Sistemática Não-Alinhada. Além disso, pode-se inclusive selecionar elementos em conglomerados

Tamanho da Amostra

Quanto amostrar?

depende:

da variabilidade original dos dados (maior variância $\Rightarrow$ maior n)

da precisão requerida no trabalho (maior precisão $\Rightarrow$ maior n)

do tempo disponível (menor o tempo $\Rightarrow$ menor n)

do custo da amostragem (maior o custo $\Rightarrow$ menor n)

Em geral, é calculado com base no parâmetro que se deseja estimar e leva em

consideração as **incertezas inerentes** a esta estimação:

a) variação “natural” dos dados (variância populacional)

b) erros de estimativa


Tamanho da Amostra

$$\bar{X} - \mu \sim N\left(0, \frac{\sigma^2}{n}\right)$$

Média

$$P\left(-z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \bar{X} - \mu < z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

$$e = z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \Rightarrow n = \frac{(z_{\alpha/2})^2 \sigma^2}{e^2}$$



- A variância populacional deve ser conhecida
- Pode-se estimar a variância populacional através de uma "pré-amostragem"
nesse caso, o tamanho da amostra é aquele que for viável (tempo, custo, etc)
se o tamanho estimado for maior que o utilizado na pré-amostragem,
complementa-se a amostragem, reestima-se a variância e recalcula-se o
tamanho da amostra até atingir o tamanho ideal


Tamanho da Amostra

Proporção

$$\hat{p} - p \sim N\left(0, \frac{pq}{n}\right)$$

$$P\left(-z_{\alpha/2} \sqrt{\frac{pq}{n}} < \hat{p} - p < z_{\alpha/2} \sqrt{\frac{pq}{n}}\right) = 1 - \alpha$$

$$e = z_{\alpha/2} \sqrt{\frac{pq}{n}} \Rightarrow n = \frac{(z_{\alpha/2})^2 pq}{e^2}$$



- Necessita-se conhecer o parâmetro p que se quer estimar!
- Pode-se estimar p através de uma "pré-amostragem"
- Pode-se adotar o valor de $p = 0,5$ que representa o "pior caso"

$$p = 0,5 \rightarrow \text{máx } \text{Var}(\hat{p}) \rightarrow \text{máx } n$$

Tamanho da Amostra

Correção para populações finitas

(quando a amostra representa mais que 5% da população)

$$n' = \frac{n}{1 + \frac{n-1}{N}}$$

n = tamanho de amostra sem correção

N = tamanho da população

n' = tamanho de amostra corrigido

Para média:
$$n' = \frac{N\sigma^2(z_{\alpha/2})^2}{(N-1)e^2 + \sigma^2(z_{\alpha/2})^2}$$

Para proporção:
$$n' = \frac{Npq(z_{\alpha/2})^2}{(N-1)e^2 + pq(z_{\alpha/2})^2}$$

Tamanho da Amostra

Exemplo: Deseja-se estimar a exatidão de um mapa de modo que o valor estimado não ultrapasse em 8% a exatidão verdadeira (para mais ou para menos), utilizando-se um nível de confiança de 95%. Suponha que a exatidão verdadeira é de 80%.

$$n = \frac{(z_{\alpha/2})^2 pq}{e^2}$$

$$n = \frac{1,96^2 0,80 0,20}{0,08^2} = 96,04 \quad \boxed{n = 96}$$

No pior caso (maior variância), a exatidão verdadeira seria de 50%.

$$n = \frac{1,96^2 0,50 0,50}{0,08^2} = 150,06 \quad \boxed{n = 150}$$

Tamanho da Amostra

Na **Amostragem Estratificada**, como distribuir as amostras em cada estrato?

Suponha que precisamos selecionar n amostras de uma população de tamanho N e que esta população está dividida em L estratos com $N_1, N_2, \dots, N_L$ elementos.

$$n_i = \frac{n}{L}$$

todos iguais

$$n_i = n \frac{N_i}{N}$$

proporcionais a N_i

$$n_i = n \frac{N_i s_i}{\sum_{i=1}^L N_i s_i}$$

tamanho ótimo
(considera a variabilidade)

O modo como as amostras são distribuídas entre os estratos têm forte impacto na estimativa de parâmetros globais (que representam toda a população) mas permite maior controle da representatividade e precisão de cada estrato.

Tamanho da Amostra

O tamanho da amostra (n) também pode considerar o erro β (tipo II)

Exemplo para **proporção**

Hipóteses


$$H_0 : p = p_0$$

$$H_1 : p < p_0$$

$$P\left(\hat{p} > p_0 - z_\alpha \sqrt{\frac{p_0 q_0}{n}}\right) = 1 - \alpha$$

Considerando H_1 verdadeira ($p = p_1$)

$$P\left(\frac{\hat{p} - p_1}{\sqrt{\frac{p_1 q_1}{n}}} > \frac{p_0 - z_\alpha \sqrt{\frac{p_0 q_0}{n}} - p_1}{\sqrt{\frac{p_1 q_1}{n}}}\right) = \beta$$




$$P\left(z_\beta \sqrt{\frac{p_1 q_1}{n}} + z_\alpha \sqrt{\frac{p_0 q_0}{n}} > p_0 - p_1\right) = \beta$$

$$n = \frac{\left(z_\beta \sqrt{p_1 q_1} + z_\alpha \sqrt{p_0 q_0}\right)^2}{(p_0 - p_1)^2}$$

Qual impacto da amostragem estratificada?

Suponha que queremos determinar a média da região abaixo considerando-se que não teríamos como acessar todos os valores mas somente uma amostra. Suponha ainda que tenhamos um mapa que poderia ser utilizado para estratificar as amostras. Qual a vantagem de se dividir as amostras entre os diferentes estratos?



Aleatória Simples

X

Aleatória Estratificada


Tamanhos de amostras:

Total	11	20	50	100
	7	14	36	72
	2	4	9	18
	2	2	5	10

*proporcional por estrato

Qual impacto da amostragem estratificada?


Aleatória Simples




$\mu = 14,03$

#11
 $\bar{X}_1 = 12,73$
 $\bar{X}_2 = 15,18$
 $\bar{X}_3 = 12,45$
 $\vdots$



Aleatória Estratificada



+



#11
(#7 #2 #2)
 $\bar{X}_1 = 16,45$
 $\vdots$



Amostras de Treinamento, Teste e Validação

Numa classificação ou numa modelagem em geral, as amostras são utilizadas para estimar os parâmetros ou para criar as regras usadas pelo classificador/modelo

Como estes ajustes visam minimizar erros, a utilização desse mesmo conjunto amostral para avaliar os resultados do classificador/modelo sempre resultarão numa superestimação dos índices de desempenho.

Dessa forma, é comum reservar parte das amostras de modo a avaliar os resultados de forma independente, gerando índices de desempenho não enviesados (nesse caso, superestimados).

Usualmente, o conjunto amostral total deve ser dividido em 3 partes excludentes:

- Treinamento
- Teste
- Validação


Os termos “teste” e “validação” podem ter seu significado trocado dependendo da literatura consultada ou então constituírem um único grupo

Amostras de Treinamento, Teste e Validação


Na prática, a definição das amostras que formarão esses grupos pode ser feita a partir de um único conjunto amostral ou então podem ser coletadas em fases diferentes do processo de classificação/modelagem.

Por exemplo, se o objetivo for avaliar uma classificação única, pode-se

- dividir as amostras coletadas em treinamento e validação, ou
- usar todas as amostras para treinamento e após a obtenção da classificação final, coletar novos pontos que serão avaliados por terceiros de forma totalmente independente.



○ treinamento



○ validação


Amostragem Iterativa

Em muitos casos, o sorteio aleatório de amostras de treinamento pode ser inviável e não garantir a representatividade dos dados analisados

Numa classificação de imagens, a escolha das amostras e posterior rotulação podem ser feitas através de interpretação visual realizada por especialistas

A seleção das amostras pode então ser feita por um processo iterativo:

- inicialmente a coleta de pontos é feita selecionando-se amostras representativas das classes de interesse
- as amostras são utilizadas para treinar o modelo
- o modelo é aplicado sobre os dados e novos pontos são escolhidos com base numa avaliação dos resultados
- repete-se o processo até que os resultados sejam considerados adequados




De modo geral, a escolha de novos pontos deve se basear em algum critério que avalie o erro e/ou o grau de incerteza de como um determinado ponto foi classificado/estimado

Uma discussão mais aprofundada sobre erros e incertezas será feita no tema "Avaliação de Classificação"

Reamostragem

A **Reamostragem** é o nome que se dá a um conjunto de técnicas ou métodos que se baseiam em ajustar ou manipular um conjunto amostral de modo a gerar novas amostragens com o objetivo de melhorar ou avaliar o desempenho de modelos



Estas técnicas se propõem a avaliar as incertezas relacionadas a obtenção de estatísticas com distribuições amostrais desconhecidas ou gerar um rearranjo nos dados de entrada de modo que modelos determinísticos gerem diferentes resultados.

Duas técnicas são comumente empregadas nesse contexto: *Jackknife* e *Bootstrap*

Também podem ser utilizadas para avaliar a significância de testes cujas estatísticas básicas não têm suas propriedades bem estabelecidas ou cujas premissas não podem ser consideradas verdadeiras.


Jackknife

Também chamado *Leave-One-Out Test*

Usado para estimar a variância e a tendência de um estimador qualquer

Baseia-se na remoção de 1 amostra do conjunto total observado (n), recalculando-se o estimador a partir dos valores restantes ($n-1$)

É de fácil implementação e possui número fixo de iterações (igual a n)



Jackknife

Suponha que um determinado parâmetro θ possa ser estimado a partir de uma amostra de n valores, ou seja,

$$\hat{\theta} = f(x_1, x_2, \dots, x_n)$$

Então a i -ésima replicação Jackknife corresponde ao valor estimado sem a amostra i :

$$\hat{\theta}_{(i)} = f(x_1, x_2, \dots, x_{i-1}, x_{i+1}, \dots, x_n)$$

Com base nessas n estimativas, pode-se calcular então:


$$\hat{\theta}_{jk} = n\hat{\theta} - (n-1)\hat{\theta}_{(.)} \quad \text{onde} \quad \hat{\theta}_{(.)} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(i)}$$

$$Var_{jk}(\hat{\theta}) = \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{(i)} - \hat{\theta}_{(.)})^2 \quad \frac{\hat{\theta}_{jk} - \theta}{\sqrt{Var_{jk}(\hat{\theta})}} \sim t_{n-1} \quad (n \text{ grande})$$

Bootstrap

Pode ser considerado uma estratégia mais abrangente que o Jackknife por permitir um maior número de replicações. Também é usado para estimar a variância e a tendência de um estimador qualquer.

Baseia-se na geração de uma nova amostra de mesmo tamanho da amostra original, a partir do sorteio aleatório **com reposição** de seus elementos.



Bootstrap

Suponha que um determinado parâmetro θ pode ser estimado a partir de uma amostra de n valores, ou seja,

$$\hat{\theta} = f(x_1, x_2, \dots, x_n)$$

Então a cada iteração j , o valor estimado a partir da amostra será:

$$\hat{\theta}_i = f(y_1, y_2, \dots, y_n) \quad \text{onde } y_k \text{ é um dos valores da amostra (com reposição)}$$

Com base nas estimativas de m iterações, pode-se calcular então:

$$\hat{\theta}_b = \frac{1}{m} \sum_{i=1}^m \hat{\theta}_i$$
$$Var_b(\hat{\theta}) = \frac{1}{m} \sum_{i=1}^m (\hat{\theta}_i - \hat{\theta})^2$$
$$\frac{\hat{\theta}_b - \theta}{\sqrt{Var_b(\hat{\theta})}} \sim t_n \quad (n \text{ grande})$$

Recomenda-se que $m \geq 200$, mas pode ser necessário $m \geq 2000$ caso o objetivo seja construir intervalos de confiança para o parâmetro θ

Bootstrap - Exemplo

Suponha que se deseja saber qual é a média geométrica de uma população e para isso obteve-se uma amostra de 10 valores:

	<i>X</i>
1	2,2
2	3,5
3	3,4
4	6,7
5	6,2
6	8,2
7	9,2
8	7,9
9	9,0
10	10,1

Qual é o valor da média geométrica desta amostra e qual a variância deste estimador?

$$mg = \sqrt[10]{2,2 \times 3,5 \times \dots \times 10,1} = 5,9844 \quad (\text{amostra completa})$$

$$Y_1 = \{3,4; 6,7; 8,2; 7,9; 10,1; 9,2; 7,9; 6,2; 3,5; 10,1\}$$

$$mg_1 = 6,8794$$

$\vdots$

$$Y_{200} = \{7,9; 9,2; 9,0; 8,2; 10,1; 8,2; 6,2; 7,9; 9,2\}$$

$$mg_{200} = 8,3158$$

$$mg_b = \frac{1}{200} \sum_{i=1}^{200} mg_i = 6,0703$$

$$Var_b(mg) = \frac{1}{200} \sum_{i=1}^{200} (mg_i - 5,9844)^2 = 0,9611$$

$$s_b(mg) = \sqrt{0,9611} = 0,9804$$


Bootstrap

No contexto de classificação, o *Bootstrap* pode ser utilizado para avaliar o desempenho do classificador

No processo de sorteio com reposição, parte das amostras não são utilizadas. Em geral, cerca de 30% das amostras ficam de fora e podem ser usadas para avaliação do classificador

No classificador *Random Forest*, por exemplo, cada árvore de decisão é gerada a partir de uma amostra obtida por *Bootstrap*. As amostras não sorteadas, chamadas de OOB (*Out of Bag*), são utilizadas para avaliar o desempenho desse classificador de modo independente pois não foram efetivamente usadas na construção de cada árvore. Todo esse processo é denominado *Bagging* (*Bootstrap Aggregating*)

O objetivo principal é reduzir a influência de dados espúrios (*outliers*) e aumentar a estabilidade (diminuir a variância)



Testes de Aleatorização

Testes de aleatorização (ou testes de permutação ou testes exatos) são típicos testes de significância onde a distribuição da estatística testada é obtida calculando-se todos os possíveis valores desta estatística reorganizando-se os valores da amostra considerando uma hipótese nula verdadeira

Uma aplicação típica é quando se deseja comparar dados pareados para avaliar se a diferença entre eles é significativamente grande para justificar que são, de fato, diferentes (por exemplo, pode-se verificar se uma determinada característica mudou de uma data para outra)

Outra aplicação é, num mapa de *Kernel*, identificar se em certas regiões há mesmo uma tendência de valores altos ou baixos, ou se o que se observa pode ter sido obtido casualmente

Nem sempre todos os rearranjos das amostras podem ser avaliados quando a amostragem é muito grande. Nesse caso, faz-se uma simulação de modo a testar o maior número possível de rearranjos (quanto maior o número de simulações melhor!)

Testes de Aleatorização - Exemplo

Uma determinada característica foi medida 8 vezes em duas datas distintas

Há evidências de que o valor dessa característica aumentou?

Amostra	Valor medido		Dif
	antes	depois	
1	3,5	4,3	0,8
2	4,7	4,4	-0,3
3	5,3	5,9	0,6
4	10,3	11,3	1,0
5	3,8	5,7	1,9
6	6,6	6,4	-0,2
7	5,1	5,1	0,0
8	9,6	10,9	1,3
		média	0,6375

Se H_0 é verdadeiro, então poderia trocar os valores entre os dois grupos

Dif média = 0,6375 ← estatística usada no teste t

Qual valor esperado caso não houvesse diferença entre os valores medidos nas duas datas (H_0)?
zero

Quão raro seria encontrar a média 0,6375 nesse caso? Ou seja, qual o valor-P associado a esta estatística?

Solução: calcular todos os valores possíveis de diferença média quando trocamos ou não os valores entre as 2 abordagens para cada amostra. Com isso, obtém-se a distribuição amostral desta estatística.

Testes de Aleatorização - Exemplo

H_0 : não há diferença entre o valor medido antes e depois (Dif média = 0)

H_1 : o valor medido depois é maior (Dif média > 0)

Se H_0 é verdadeira, então haverá 2^8 possibilidades de trocas, gerando 256 resultados diferentes

Amostra	Valor medido		Dif
	antes	depois	
1	3,5	4,3	0,8
2	4,4	4,7	0,3
3	5,3	5,9	0,6
4	10,3	11,3	1,0
5	3,8	5,7	1,9
6	6,4	6,6	0,2
7	5,1	5,1	0,0
8	9,6	10,9	1,3
		média	0,7625

...

Dif
0,8
-0,3
0,6
1,0
1,9
-0,2
0,0
1,3
0,6375

...

Amostra	Valor medido		Dif
	antes	depois	
1	4,3	3,5	-0,8
2	4,7	4,4	-0,3
3	5,9	5,3	-0,6
4	11,3	10,3	-1,0
5	5,7	3,8	-1,9
6	6,6	6,4	-0,2
7	5,1	5,1	-0,0
8	10,9	9,6	-1,3
		média	-0,7625


Testes de Aleatorização - Exemplo

H_0 : não há diferença entre o valor medido antes e depois (Dif média = 0)

H_1 : o valor medido depois é maior (Dif média > 0)

Se H_0 é verdadeira, então haverá 2^8 possibilidades de trocas, gerando 256 resultados diferentes

Amostra	Valor medido		Dif
	antes	depois	
1	3,5	4,3	0,8
2	4,7	4,4	-0,3
3	5,3	5,9	0,6
4	10,3	11,3	1,0
5	3,8	5,7	1,9
6	6,6	6,4	-0,2
7	5,1	5,1	0,0
8	9,6	10,9	1,3
		média	0,6375



Valor-P = $P(\text{Dif média } H_0 \text{ verdadeiro} \geq \text{Dif média observada}) = 3,13\%$

Conclusão: rejeita-se H_0 a 5% de significância, ou seja, há evidências de que o valor, em média, aumenta na última medição


Validação Cruzada

Como dito anteriormente, é sempre melhor usar um conjunto de amostras independentes para avaliar/validar os resultados de uma modelagem ou classificação

Tipicamente, na validação cruzada, a amostra é particionada aleatoriamente em K subconjuntos disjuntos (*K -Folds*)

O valor de K é em geral 5 ou 10. Quando K é igual ao número de amostras, então esse método é conhecido como Validação Cruzada LOO (*Leave One Out Cross Validation*)

O método *K -Folds* consiste em usar cada uma das partições como amostras de validação e as demais como treinamento. Assim consegue-se realizar K validações independentes



Em geral, os resultados das validações são sintetizados em uma medida de tendência central (média, mediana, etc) ou então através de um intervalo de credibilidade ou um boxplot

Boosting


Não se trata de técnica tradicional de reamostragem como *Bootstrap* e *Jackknife*

Consiste em alterar a importância de cada amostra, através de pesos, de modo a favorecer algumas amostras em detrimento de outras

O *AdaBoost*, por exemplo, ajusta o peso de cada amostra, aumentando a importância de amostras mal classificadas/estimadas de modo a diminuir os erros de classificação/estimação

Num classificador baseado em árvores de decisão, por exemplo, a primeira árvore é construída com base em todas as amostras. Essa árvore é usada para avaliar cada amostra, aumentando-se o peso daquelas mal classificadas. Uma nova árvore é gerada. Esse processo é repetido um determinado número de vezes

O objetivo principal desse método é reduzir a tendência (ou viés), tentando-se minimizar os erros



Balanceamento de Classes/Estratos

Muitas técnicas estatísticas são fortemente influenciadas pelo desbalanceamento das classes ou estratos usados no treinamento. Em geral, classes minoritárias são preteridas ou negligenciadas durante o processo de treinamento de modelos supervisionados

Algumas técnicas podem ser aplicadas para mitigar esse tipo de problema:

- *Oversampling* (Superamostragem)

Aumenta-se o número de amostras da classe minoritária: superamostragem aleatória (duplicação de amostras), SMOTE, ADASYN

- *Undersampling* (Subamostragem)

Reduz-se o número de amostras da classe majoritária: subamostragem aleatória (eliminação de amostras), remoção de amostras redundantes ou pouco informativas (usando critérios de proximidade)

Perturbação aleatória

Em alguns casos (amostragens pequenas, modelos determinísticos, por exemplo), a introdução de perturbações nos dados de entrada podem ajudar o processo de modelagem

- Estimação de distribuições de resultados em modelos determinísticos

O método de Monte Carlo pode ser empregado para estimar a distribuição de resultados

- Simulação de dados reais

A perturbação permite avaliar a incerteza “natural” esperada em dados reais

- Robustez do modelo

A adição de ruídos aos dados ou aos parâmetros do modelo permitem avaliar sua estabilidade e sensibilidade

- Otimização

Em algoritmos de otimização, como algoritmos genéticos, a perturbação aleatória pode favorecer a busca por soluções globais por evitar que o mesmo fique “preso” a soluções locais

Aprendizado Ativo – *Active Learning*

É uma técnica na qual o algoritmo de aprendizado busca especificamente os dados que são mais informativos para o modelo em vez de ser treinado por todo o conjunto de dados disponível

Em vez de sortear um subconjunto de amostras aleatoriamente (por alguma técnica de reamostragem), o modelo seleciona as amostras que considera mais informativas ou atribui pesos às amostras, de acordo com algum critério:

- a) Maior incerteza: o algoritmo privilegia as amostras que tem maior dificuldade para classificar ou maior erro ao estimar seu valor
- b) Maior acerto: o algoritmo escolhe amostras que tenham maior impacto no desempenho final do modelo