
Estatística: Aplicação ao Sensoriamento Remoto

SER 204

Avaliação de Classificação


Camilo Daleles Rennó

camilo.renno@inpe.br

acesso do conteúdo do curso em <https://cdrenno.github.io/Estatistica/>

Classificação de Imagens

Classificação é o processo de extração de informação em imagens para reconhecer padrões e objetos homogêneos que são utilizados para mapear áreas da superfície terrestre que correspondem aos temas de interesse.




A partir de um conjunto de dados, através de um processo de rotulação (classificação), obtém-se uma **imagem classificada** (ou **mapa temático**).

Este processo inclui toda a preparação dos dados (seleção e pré-processamento), definição das classes de interesse, escolha do método de classificação e das funções que serão utilizadas pelo classificador para distinguir as classes, e a classificação propriamente dita (geração da imagem classificada).



Tipos de Classificação

- Computacional ou interpretação visual






Tipos de Classificação

- Pixel a pixel ou por região




Tipos de Classificação

- Pontual ou contextual




Tipos de Classificação

- Supervisionada ou automática (não supervisionada)






Supervisionado
Maxver Gaussiano (3 classes)



Não supervisionado
K-médias (10 classes)



Tipos de Classificação

- Probabilística ou baseada em métricas de distância ou regras de decisão




Tipos de Classificação

- Rígida (Discreta ou *Crisp*) ou *Fuzzy* (Contínua)



Maxver Gaussiano (3 classes)
Máxima Probabilidade



36,8% Floresta
63,2% Regeneração
0% Solo Exposto


Maxver Gaussiano (3 classes)
Fuzzy – Probabilidade

Avaliação dos Erros de Classificação

Para classificadores supervisionados, as regras de decisão ou funções de pertinência são ajustadas segundo um conjunto de amostras de modo a minimizar **erros de classificação**

Numa classificação tradicional (rígida), considera-se que todo elemento (pixel ou polígono) está associado a uma única classe temática.

O erro surge sempre que esta associação diverge da **VERDADE**.



certo ou errado?
quão certo está?

A **VERDADE**, muitas vezes, representa apenas uma **REFERÊNCIA** (resultado ideal).

Desafio

Como avaliar o desempenho de um classificador através do resultado da classificação, ou seja, através do mapa obtido?

O que estamos avaliando afinal?

Dados de entrada (atributos)?

dados são suficientes para descrever a complexidade da região estudada?

Método de classificação?

utiliza um método ou regras que fazem sentido para os meus dados?

Poder discriminatório do classificador?

a definição das classes é realmente clara?

Qualidade das amostras fornecidas?

a seleção das amostras foi bem feita? São representativas? São realmente confiáveis?

Questões básicas

- Amostragem

O que amostrar?

Quanto amostrar?

Como amostrar?

Como separar as amostras entre as diferentes fases de classificação/avaliação?

- Índices de avaliação

Como representar erros e acertos?

Como representar incertezas?

Melhor usar índices globais ou por classe?

Como se pode comparar classificadores?

- O que não abordaremos?

Acurácia posicional

Especificação Técnica para Controle de Qualidade de Dados Geoespaciais

Erro e Incerteza

Na classificação, a incerteza surge devido a diferentes fatores: resolução espacial (mistura de classes), definição das classes, escolha de amostras representativas, escolha de atributos representativos (capazes de discriminar as classes de interesse), escolha das funções discriminantes ou de pertinência (e de seus parâmetros), erros aleatórios e sistemáticos, etc.

Existem vários tipos de incerteza e o significado atribuído ao termo incerteza aparece com diferentes interpretações na literatura: **erro**, **ambiguidade** ou **imprecisão**.

Avaliação dos Erros de Classificação

avalia os erros e confusões entre classes de acordo com uma referência

Exatidão ou Acurácia

Avaliação da Incerteza

avalia como as questões estocásticas afetam o resultado da classificação

Mapas de Incerteza

Avaliação dos Erros de Classificação

A **referência** pode ser obtida a partir de:

- dados pré-existentes (levantamentos, mapas, literatura, etc)
apesar de ter custo quase zero, as informações podem estar desatualizadas
erros pré-existentes são raramente conhecidos
pode haver diferentes definições para a mesma classe (diferença semântica)
- dados de campo
em geral, envolve um custo elevado (logística, localização precisa, equipes grandes, etc)
pode haver grande defasagem temporal entre o momento de obtenção do dado usado na classificação e o de checagem (comum em ambientes dinâmicos)
a amostragem pode ser enviesada
somente pontos com fácil acesso são checados
o uso de drones pode ajudar nesse caso
- fotointerpretação (geralmente usando imagens com resolução mais fina)
apesar do baixo custo, o resultado depende da experiência do fotointérprete (ideal: diferente de quem fez a classificação)
pode ser enviesado ao induzir um resultado positivo quando já se conhece o resultado da classificação (ideal: total independência entre os processos)
também pode ter problemas em ambientes dinâmicos (defasagem temporal)

Avaliação dos Erros de Classificação

Fatores importantes a serem considerados durante a avaliação dos erros:

- Unidade amostral utilizada na avaliação
pontos, objetos (polígonos ou linhas), grupo de pontos ou objetos
tem impacto direto sobre a interpretação dos resultados
- Independência das amostras
supõe-se que não há influência entre as amostras escolhidas, ou seja, não se considera explicitamente a existência de relações espaciais ou temporais entre amostras
a autocorrelação espacial tem impacto maior se for utilizar testes estatísticos de significância pois afeta principalmente o cálculo da precisão (variância) associada aos índices testados
- Representação dos acertos/erros
como explicitar os erros e acertos? Índices globais, por classe e/ou distribuição espacial?
- Tamanho de amostra e estratégia amostral
essencial para avaliar corretamente acertos e erros da classificação
afeta diretamente a precisão das estimativas obtidas

Representação dos Acertos/Erros

A avaliação dos acertos/erros de uma classificação pode ser feita através de:

- Tabelas (matriz de confusão) – representa os acertos e confusões/erros entre classes
- Índices globais – representam características gerais
- Índices por classes – representam características particulares de cada classe
- Índice F1 score* – representa o balanço entre precisão e sensibilidade (*recall*)
- Curva ROC e AUC* – representa relação entre falsos e verdadeiros positivos

* específico para classificações com 2 classes (presente/ausente)

Matriz de Confusão

A partir de um conjunto de n pontos (polígonos ou grupos) sorteados/escolhidos, a classificação é comparada à referência obtendo-se a

Matriz de Confusão

(matriz de erro)

		Referência				
		C_1	C_2	$\dots$	C_c	Total
Classificação	C_1	n_{11}	n_{12}	$\dots$	n_{1c}	n_{1+}
	C_2	n_{21}	n_{22}	$\dots$	n_{2c}	n_{2+}
	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
	C_c	n_{c1}	n_{c2}	$\dots$	n_{cc}	n_{c+}
	Total	n_{+1}	n_{+2}	$\dots$	n_{+c}	n

n_{ij} : número de pontos da classe j (referência), classificados na classe i (classificação)

n_{kk} : número total de pontos corretamente classificados da classe k

n_{+j} : número total de pontos avaliados da classe j na referência

n_{i+} : número total de pontos avaliados da classe i na classificação

Matriz de Confusão

Observações importantes:

- considera que as classes são excludentes (cada ponto pertence a apenas uma classe);
- mesmas classes na Classificação e na Referência (matriz quadrada);
- todos os pontos avaliados devem pertencer a alguma classe, ou seja, o classificador não pode considerar a classe “não classificado”;
- a utilização de classes muito semelhantes (representando subtipos) pode induzir a um excesso de erros (ou confusões) que certamente prejudicarão a avaliação global da classificação;
- a interpretação dos resultados está diretamente dependente da unidade amostral adotada (pontos ou polígonos isolados ou em grupos).

Avaliação da Exatidão

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	1	4	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	0	0
	Total	33	49	54	12	146

#pontos corretamente classificados

#pontos incorretamente classificados

#pontos/classificados na classificação

#pontos/classificados na referência

#pontos amostrados

Amostragem

O número ideal de amostras pode ser calculado com base na distribuição binomial, considerando-se os erros do tipo I e/ou II. Essas abordagens desconsideram as confusões entre classes.

Congalton (1991)* e Olofsson et al. (2014)** sugerem no mínimo 50 pontos para cada classe num caso geral, e 100 pontos por classe caso a área avaliada seja muito grande ou o número de classes seja maior do que 12.

O balanceamento entre classes pode afetar fortemente a interpretação dos índices

A amostragem aleatórias simples tende a representar bem as proporções entre classes
cuidado quando há classes raras (podem não ser avaliadas adequadamente!)

A amostragem estratificada proporcional também preserva essa proporcionalidade
em geral é feita com relação à classificação obtida (*a posteriori*) devido a ausência de uma referência completa

classes menos representativas tem estimativas menos precisas (maior incerteza)

Na amostragem estratificada com mesmo número de amostras por classe, perde-se a relação com as proporções reais

Nesses casos, é melhor trabalhar com matrizes de confusões não enviesadas

*Congalton, R. G. A Review of Assessing the Accuracy of Classifications of Remotely Sensed Data. *Remote Sens. Environ.*, 37(1):35-46, 1991

**Olofsson, P. et al. Good practices for estimating area and assessing accuracy of land change. *Remote Sens. Environ.* 148:42–57, 2014

Matriz de Confusão Não Enviesada

Stehman e Foody (2009) sugerem sempre utilizar a matriz não enviesada (ajustada para as proporções de cada classe na classificação)

		Referência				
		C ₁	C ₂	...	C _c	Total
Classificação	C ₁	n ₁₁	n ₁₂	...	n _{1c}	n ₁₊
	C ₂	n ₂₁	n ₂₂	...	n _{2c}	n ₂₊
	⋮	⋮	⋮	⋮	⋮	⋮
	C _c	n _{c1}	n _{c2}	...	n _{cc}	n _{c+}
	Total	n ₊₁	n ₊₂	...	n _{+c}	n

		Referência				
		C ₁	C ₂	...	C _c	Total
Classificação	C ₁	p_{11}	p_{12}	...	p_{1c}	p_{1+}
	C ₂	p_{21}	p_{22}	...	p_{2c}	p_{2+}
	⋮	⋮	⋮	⋮	⋮	⋮
	C _c	p_{c1}	p_{c2}	...	p_{cc}	p_{c+}
	Total	p_{+1}	p_{+2}	...	p_{+c}	1

Para **amostragens aleatórias** onde todas as amostras têm igual probabilidade de serem escolhidas:

$$\hat{p}_{ij} = \frac{n_{ij}}{n}$$

Para **amostragens estratificadas**:

$$\hat{p}_{ij} = \frac{n_{ij}}{n_{i+}} \frac{N_{i+}}{N}$$

N_{i+} = área classificada como C_i
 N = área total classificada

Avaliação da Exatidão

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

$$\text{Exatidão Total} = \frac{\sum_{k=1}^c n_{kk}}{n} \quad \left\{ \begin{array}{l} \text{mínimo} = 0 \\ \text{máximo} = 1 \text{ (ou 100\%)} \end{array} \right.$$

(ou Global)

$$= \frac{27 + 35 + 53 + 52}{200} = \frac{167}{200} = 83,5\%$$

Avaliação da Exatidão

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

O que significa uma exatidão de 83,5% ?

- Se uma amostra, dentre as 200, fosse escolhida ao acaso, a probabilidade desta estar corretamente classificada seria de 83,5%
- Se uma amostra (ponto ou polígono) fosse escolhida ao acaso no mapa, a probabilidade desta estar corretamente classificada seria também de 83,5%?

somente se a amostragem representar as reais proporções de cada classe!

Avaliação da Exatidão

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Usando a matriz de confusão não enviesada :

	Proporção (Classificação)		
A	25%	1%	1%
B	25%	2%	95%
C	25%	2%	3%
D	25%	95%	1%
exatidão	83,68%	98,88%	76,41%

Exatidão
83,5%

Avaliação da Exatidão por Classe

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Ponto de vista do
Produtor
(Referência)

Quanto da classe k foi
identificada
corretamente pelo
classificador?

$$\text{Exatidão do Produtor da classe } k = \frac{n_{kk}}{n_{+k}}$$

$$\text{Exatidão do Produtor da classe B} = \frac{35}{49} = 71,4\%$$

$$\text{Erro de omissão da classe B} = \frac{6 + 8 + 0}{49} = \frac{14}{49} = 28,6\%$$

Avaliação da Exatidão por Classe

		Referência				Total
		A	B	C	D	
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Ponto de vista do
Usuário
(Classificação)

Quanto do que foi
classificado como k é
realmente da classe k ?

$$\text{Exatidão do Usuário da classe } k = \frac{n_{kk}}{n_{k+}}$$

$$\text{Exatidão do Usuário da classe C} = \frac{53}{69} = 76,8\%$$

$$\text{Erro de comissão (inclusão) da classe C} = \frac{0 + 8 + 8}{69} = \frac{16}{69} = 23,2\%$$

Avaliação da Exatidão por Classe

não é necessário
apresentar a
exatidão e o erro
simultaneamente!

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Classe	exatidão produtor	erro omissão	exatidão usuário	erro inclusão
A	81,8%	18,2%	81,8%	18,2%
B	71,4%	28,6%	76,1%	23,9%
C	98,1%	1,9%	76,8%	23,2%
D	81,2%	18,8%	100,0%	0,0%

Classe C:

Praticamente tudo que é realmente C está no mapa, mas nem tudo que está no mapa como C é realmente C

Classe D:

tudo que está no mapa como D é realmente D, mas nem tudo que é realmente D está no mapa

Classe A:

erros de omissão e inclusão se compensam. Apesar dos erros, o mapa estima bem a área ocupada por essa classe!

Avaliação da Exatidão

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

$\div 200 \cong P(C_i)$

$\div 200 \cong P(R_i)$

Exatidão Total = 83,5%

E se a classificação fosse realizada de modo totalmente aleatório?

$$P(C_i \cap R_j) = P(C_i) \cdot P(R_j)$$

Avaliação da Exatidão

$$\frac{33 * 33}{200}$$

		Referência				
Classificação		A	B	C	D	Total
	A	5,45	8,09	8,91	10,56	33
	B	7,59	11,27	12,42	14,72	46
	C	11,39	16,91	18,63	22,08	69
	D	8,58	12,74	14,04	16,64	52
	Total	33	49	54	64	200

$$\text{Exatidão Total} = \frac{5,45 + 11,27 + 18,63 + 16,64}{200} = \frac{51,99}{200} = 25,99\%$$

Ou seja, 25,99% do acerto pode ter sido conseguido de modo casual !!!

Medida de Concordância Kappa

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Índice Kappa (κ) – medida de concordância

$$\hat{\kappa} = \frac{\theta_1 - \theta_2}{1 - \theta_2} \quad \theta_1 = \frac{\sum_{k=1}^c n_{kk}}{n} \quad \begin{array}{l} \text{exatidão total} \\ \text{(observada)} \end{array}$$

$$\kappa \left\{ \begin{array}{ll} \text{mínimo} < 0 & (\theta_1 < \theta_2) \\ \text{máximo} = 1 & (\theta_1 = 1) \end{array} \right. \quad \theta_2 = \frac{\sum_{k=1}^c n_{k+} n_{+k}}{n^2} \quad \begin{array}{l} \text{exatidão total} \\ \text{(se classificação fosse aleatória)} \end{array}$$

Índice Kappa

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Índice Kappa (κ) – medida de concordância

$$\theta_1 = \frac{\sum_{k=1}^c n_{kk}}{n} = 0,8350 \quad \hat{\kappa} = \frac{\theta_1 - \theta_2}{1 - \theta_2} = \frac{0,8350 - 0,2599}{1 - 0,2599} = 0,7777$$

$$\theta_2 = \frac{\sum_{k=1}^c n_{k+} n_{+k}}{n^2} = 0,2599$$

Se a classificação fosse totalmente aleatória, qual seria o valor esperado para o kappa?

zero $\Rightarrow$ Teste de hipótese

Índice Kappa

$$\hat{\kappa} = \frac{\theta_1 - \theta_2}{1 - \theta_2} \quad \theta_1 = \frac{\sum_{k=1}^c n_{kk}}{n} \quad \theta_2 = \frac{\sum_{k=1}^c n_{k+} n_{+k}}{n^2}$$

$$\text{Var}(\hat{\kappa}) = \frac{1}{n} \left[\frac{\theta_1(1 - \theta_1)}{(1 - \theta_2)^2} + \frac{2(1 - \theta_1)(2\theta_1\theta_2 - \theta_3)}{(1 - \theta_2)^3} + \frac{(1 - \theta_1)^2(\theta_4 - 4\theta_2^2)}{(1 - \theta_2)^4} \right]$$

$$\theta_3 = \frac{\sum_{k=1}^c n_{kk}(n_{k+} + n_{+k})}{n^2}$$

$$\theta_4 = \frac{\sum_{i=1}^c \sum_{j=1}^c n_{ij}(n_{i+} + n_{+j})^2}{n^3}$$

Pressupondo **amostras independentes** e **TLC válido** (amostra grande):

$$Z = \frac{\hat{\kappa} - \kappa}{\sqrt{\text{Var}(\hat{\kappa})}} \sim N(0,1)$$

Índice Kappa – Exemplo 1

A fim de avaliar a qualidade de uma classificação, 150 pontos foram selecionados aleatoriamente, avaliando-se cada ponto segundo uma referência. O resultado é apresentado na matriz de confusão abaixo:

		referência				
		A	B	C	D	E
classificação	A	13	0	3	0	0
	B	8	10	5	0	0
	C	8	4	27	0	0
	D	2	0	1	25	0
	E	0	0	0	0	44

Verifique se há mesmo uma concordância entre a classificação e a referência através de um teste de hipótese para o Kappa.

Índice Kappa – Exemplo 1

		referência				
		A	B	C	D	E
classificação	A	13	0	3	0	0
	B	8	10	5	0	0
	C	8	4	27	0	0
	D	2	0	1	25	0
	E	0	0	0	0	44

$$\hat{\kappa} = 0,7364$$

$$\text{Var}(\hat{\kappa}) = 0,001671$$

$$Z = \frac{\hat{\kappa} - \kappa}{\sqrt{\text{Var}(\hat{\kappa})}} \sim N(0,1)$$

$$H_0: \kappa = 0$$

$$H_1: \kappa > 0$$

Se H_0 for verdadeira, então:

$$z = \frac{\hat{\kappa}}{\sqrt{\text{Var}(\hat{\kappa})}} = \frac{0,7364}{\sqrt{0,001671}} = 18,01 \quad \text{valor-P} = 0,0000$$


Conclusão: rejeita-se H_0 com 5% de significância, ou seja, há concordância entre a classificação e a referência

Comparando Avaliações...


Em muitos casos, deseja-se verificar se duas classificações apresentam o mesmo desempenho ou se uma das classificações tem resultados mais favoráveis que outra.

Uma questão fundamental aqui é saber se as amostras utilizadas para as avaliações são as mesmas ou cada classificação foi avaliada com um conjunto diferente de amostras, ou seja, as duas classificações foram avaliadas de forma independente uma da outra.

Avaliação usando mesmas amostras



Avaliação usando amostras independentes



Avaliação a partir de 2 amostragens não relacionadas

Nesse caso, as avaliações são **independentes** entre si!

Pressupondo-se **TLC válido** (amostra grande), tem-se

- para a exatidão (θ):

$$Z = \frac{(\hat{\theta}_1 - \hat{\theta}_2) - (\theta_1 - \theta_2)}{\sqrt{\hat{\theta}(1 - \hat{\theta}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim N(0,1) \quad \hat{\theta} = \frac{\hat{\theta}_1 + \hat{\theta}_2}{2}$$

- para o Kappa:

$$Z = \frac{(\hat{\kappa}_1 - \hat{\kappa}_2) - (\kappa_1 - \kappa_2)}{\sqrt{Var(\hat{\kappa}_1) + Var(\hat{\kappa}_2)}} \sim N(0,1)$$

Avaliação a partir de 2 amostragens relacionadas

Nesse caso, as avaliações foram feitas usando-se as mesmas amostras de referência para ambas classificações

- para a exatidão:

teste de McNemar (Foody, 2004)

		Classificação 2	
		Correto	Incorreto
Classificação 1	Correto	f_{11}	f_{12}
	Incorreto	f_{21}	f_{22}

$$\chi^2 = \frac{(f_{12} - f_{21})^2}{f_{12} + f_{21}} \sim \chi_1^2$$

Teste qui-quadrado unilateral a direita

- para a Kappa:

Não há um teste formal para comparar dois índices Kappa para amostras relacionadas!

Índice Kappa – Exemplo 2

Dois classificadores foram testados. Há uma suposição de que o segundo classificador gera resultados superiores (melhor exatidão) quando comparado ao primeiro classificador. Para checar esta hipótese, 150 pontos foram escolhidos **aleatoriamente** para cada avaliação. As matrizes de confusão resultantes das avaliações são apresentadas a seguir:

		referência				
		A	B	C	D	E
classificação 1	A	13	0	3	0	0
	B	8	10	5	0	0
	C	8	4	27	0	0
	D	2	0	1	25	0
	E	0	0	0	0	44

		referência				
		A	B	C	D	E
classificação 2	A	25	0	2	0	0
	B	2	28	0	0	4
	C	0	2	30	2	0
	D	0	0	1	33	0
	E	0	0	0	0	21

Verifique se o segundo classificador realmente apresenta uma concordância com a referência superior a do primeiro classificador comparando-se os valores Kappa de cada avaliação.

Índice Kappa – Exemplo 2

		referência				
		A	B	C	D	E
classificação 1	A	13	0	3	0	0
	B	8	10	5	0	0
	C	8	4	27	0	0
	D	2	0	1	25	0
	E	0	0	0	0	44

$$\hat{\kappa}_1 = 0,7364 \quad \text{Var}(\hat{\kappa}_1) = 0,001671$$

$$Z = \frac{(\hat{\kappa}_1 - \hat{\kappa}_2) - (\kappa_1 - \kappa_2)}{\sqrt{\text{Var}(\hat{\kappa}_1) + \text{Var}(\hat{\kappa}_2)}} \sim N(0,1)$$

		referência				
		A	B	C	D	E
classificação 2	A	25	0	2	0	0
	B	2	28	0	0	4
	C	0	2	30	2	0
	D	0	0	1	33	0
	E	0	0	0	0	21

$$\hat{\kappa}_2 = 0,8911 \quad \text{Var}(\hat{\kappa}_2) = 0,000831$$

Importante: amostragens devem ser independentes.
Ou seja, cada avaliação deve usar um conjunto diferente de validação!!!

$$H_0: \kappa_1 - \kappa_2 = 0$$

$$H_1: \kappa_1 - \kappa_2 < 0 \quad \text{Se } H_0 \text{ for verdadeira, então:}$$

$$z = \frac{\hat{\kappa}_1 - \hat{\kappa}_2}{\sqrt{\text{Var}(\hat{\kappa}_1) + \text{Var}(\hat{\kappa}_2)}} = \frac{0,7364 - 0,8911}{\sqrt{0,001671 + 0,000831}} = -3,09 \quad \text{valor-P} = 0,0010$$

Conclusão: rejeita-se H_0 com 5% de significância, ou seja, a concordância entre a classificação e a referência é maior para o classificador 2

Independência das Amostras

A independência (espacial e temporal) na coleta das amostras é importante pois amostras não independentes representam redundância e portanto podem gerar problemas principalmente na estimação das incertezas (variância) associadas ao índice avaliado.


Em geral, um grande número de amostras correlacionadas geram a falsa impressão de que as estimativas são muito precisas!

$$Var(\theta) = \frac{\theta(1 - \theta)}{n}$$


$$Var(\hat{\kappa}) = \frac{1}{n} \left[\frac{\theta_1(1 - \theta_1)}{(1 - \theta_2)^2} + \frac{2(1 - \theta_1)(2\theta_1\theta_2 - \theta_3)}{(1 - \theta_2)^3} + \frac{(1 - \theta_1)^2(\theta_4 - 4\theta_2^2)}{(1 - \theta_2)^4} \right]$$

Índice Kappa – Exemplo 3

Avalie se a classificação abaixo apresenta Kappa superior a 0,7, considerando-se a existência de uma referência que recobre toda a área classificada.




classificação




referência

Índice Kappa – Exemplo 3



classificação



referência

Selecionando-se todos os pontos...

$$H_0: \kappa = 0,7$$

$$H_1: \kappa > 0,7$$

$$\hat{\kappa} = 0,7400$$

$$\text{Var}(\hat{\kappa}) = 0,000103$$

Se H_0 for verdadeira, então:

$$Z = \frac{\hat{\kappa} - 0,7}{\sqrt{\text{Var}(\hat{\kappa})}} = 3,9475$$


$$\text{Valor-P} = 3,95 \cdot 10^{-5}$$

		REFERÊNCIA					
		Red	Yellow	Green	Blue	Grey	$n_{i\cdot}$
CLASSIF.	Red	360	0	110	0	0	470
	Yellow	0	410	0	70	0	480
	Green	0	90	390	0	50	530
	Blue	80	0	0	370	0	450
	Grey	60	0	0	60	450	570
$n_{\cdot j}$		500	500	500	500	500	2500


~~Conclusão: rejeita-se H_0 com 5% de significância, ou seja, o kappa dessa classificação é maior que 0,7.~~

(esta conclusão pode estar equivocada pois desconsiderou a dependência espacial)

Índice Kappa – Exemplo 3



classificação



referência

Selecionando-se
250 pontos...

$$H_0: \kappa = 0,7$$

$$H_1: \kappa > 0,7$$

$$\hat{\kappa} = 0,7336$$

$$\text{Var}(\hat{\kappa}) = 0,00103$$

Se H_0 for verdadeira, então:


$$Z = \frac{\hat{\kappa} - 0,7}{\sqrt{\text{Var}(\hat{\kappa})}} = 1,0447$$

$$\text{Valor-P} = 0,1481$$


		REFERÊNCIA					
		Red	Yellow	Green	Blue	Grey	n_{it}
CLASSIF.	Red	26	0	8	0	0	34
	Yellow	0	50	0	8	0	58
	Green	0	8	35	0	6	49
	Blue	14	0	0	33	0	47
	Grey	6	0	0	3	53	62
n_{ij}		46	58	43	44	59	250

Conclusão: aceita-se H_0 , ou seja, o valor de kappa observado não é significativamente (a 5%) maior que 0,7

Índice Kappa – Exemplo 4



classificação



referência

Por que acreditar nesta única amostra de 250 pontos?

A cada nova amostragem de 250 pontos, uma nova matriz de confusão seria obtida e portanto um novo valor de kappa seria estimado...

$H_0: \kappa = 0,7$

Nova abordagem:

$H_1: \kappa > 0,7$

A escolha dos 250 pontos amostrais é repetido muitas vezes (pelo menos 1000 vezes).

Para cada amostragem, determina-se a matriz de confusão e calcula-se o kappa

Calcula-se a frequência (probabilidade) com que H_0 é aceita

Se esta frequência for baixa (menor que 5%, por exemplo), conclui-se que é relativamente "raro" aceitar H_0 e portanto rejeita-se H_0 .

Suponha que, após a simulação de 10000 valores de kappa, 10,78% das vezes H_0 foi aceito...

Conclusão: aceita-se H_0 , ou seja, não há fortes evidências que levem a conclusão que o kappa seja de fato maior que 0,7

Outros Índices

Kappa condicional

Avalia a concordância para uma determinada classe

Kappa ponderado

Cada célula ij da matriz de confusão pode receber um peso ($0 \leq w_{ij} \leq 1$) permitindo que certos erros sejam mais importantes que outros

Tau

O índice Kappa pressupõe que ambas as probabilidades marginais (classificação e referência) sejam conhecidas antes mesmo da classificação

Para o índice Tau, utiliza-se as probabilidades *a priori* de cada classe (p_k) ao invés de estimá-las pelas proporções marginais obtidas após a classificação

Assim, este índice pode ser obtido por:

$$\hat{\tau} = \frac{\theta_1 - \theta'_2}{1 - \theta'_2} \quad \theta_1 = \frac{\sum_{k=1}^c x_{kk}}{n} \quad \theta'_2 = \frac{\sum_{k=1}^c p_k x_{+k}}{n}$$

Na ausência de informação, utiliza-se o mesmo valor para todos p_k (classes equiprováveis, ou seja, $p_k = 1/c$)

Críticas ao Kappa*

- É sempre melhor (mais útil) focar na discordância e tentar explicar os erros do que focar na concordância e se preocupar como a aleatoriedade explica parte do acerto observado – o que é a essência do Kappa;
- Não se conhece nenhum artigo onde os autores mudaram a conclusão quando compararam a exatidão total e o Kappa. Em geral, os autores apenas apresentam simultaneamente a exatidão total e o Kappa junto ao mapa avaliado (**desaconselhável!**);
- A avaliação da significância do Kappa é feita pressupondo-se que parte da exatidão total observada é casual (Kappa = 0?). **Isso é quase sempre inútil**;
- Pontius e Millones (2011) e Pontius e Santacruz (2014) sugerem particionar os erros em diferentes componentes:
 - *Quantity* (quantidade, grandeza)
 - *Allocation* (alocação, atribuição):
 - *Exchange* (troca, permuta)
 - *Shift* (mudança, deslocamento)

Estes índices são mais úteis quando empregados na análise de trajetórias (mapas obtidos em 2 datas)

*Pontius, R. G.; Millones, M. Death to Kappa: birth of quantity disagreement and allocation disagreement for accuracy assessment. International Journal of Remote Sensing, 32(15): 4407-4429, 2011

Pontius, R. G.; Santacruz, A. Quantity, exchange, and shift components of difference in a square contingency table. International Journal of Remote Sensing, 35(21): 7543-7554, 2014

Índice *Quantity*

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Observe que para a classe A, os erros de omissão são compensados pelos erros de inclusão.

Neste caso, a área estimada pela classificação é a mesma da referência, ou seja, a classificação poderia ser utilizada para estimar a *quantidade* da classe A presente na referência.

Índice *Quantity*

		Referência				
Classificação		A	B	C	D	Total
	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Já para classe B, há 3 amostras a mais na referência do que na classificação, o que representa um erro de 1,5% em relação ao total.

Classe	<i>Quantity</i>
A	0,0%
B	1,5%
C	7,5%
D	6,0%
Total	7,5%

Considerando todas as classes, *Quantity* = 7,5%

$$Q_T = \frac{Q_A + Q_B + Q_C + Q_D}{2}$$

Índice *Allocation*

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Em toda a matriz observa-se um total de 33 amostras erradas, o que representa 16,5%, ou seja, 100% – exatidão.

Como o erro devido a quantidade foi de 7,5%, então o restante, 9%, é devido a problemas de alocação.

Mas qual tipo de erro de alocação? Permuta ou mudança?

Índice *Allocation: Exchange or Shift?*

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Observe que para a classe A, todos os erros foram devidos à permuta com a classe B, ou seja, amostras classificadas como B foram compensadas pelas amostras da classe B erroneamente classificadas como A. Dessa forma, para a classe A, todo o erro de alocação foi do tipo *exchange* (permuta) totalizando 12 amostras ($6 + 6$) ou 6% do total.

Índice *Allocation: Exchange or Shift?*

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8 (7)	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Agora, analisando-se os erros relacionados à classe B, observa-se que 12 (6+6) amostras foram permutadas entre as classe A e B, e 2 (1+1) entre as classes B e C, totalizando 14 amostras (*Exchange* = 7%).


Nesse caso, dos 25 erros observados, houveram 3 erros de quantidade (*Quantity* = 1,5%), 14 erros de permuta (*Exchange* = 7%), restando 8 erros (7+4-3) por mudança (*Shift* = 4%).

Índices propostos por Pontius

		Referência				
		A	B	C	D	Total
Classificação	A	27	6	0	0	33
	B	6	35	1	4	46
	C	0	8	53	8	69
	D	0	0	0	52	52
	Total	33	49	54	64	200

Classe	Quantity Allocation	
A	0%	6%
B	1,5%	11%
C	7,5%	1%
D	6%	0%
Total	7,5%	9%

Exchange	Shift
6%	0%
7%	4%
1%	0%
0%	0%
7%	2%



Avaliação da Exatidão – Comentários Gerais

- A Matriz de Confusão constitui a parte mais importante na avaliação desde que represente corretamente os acertos e erros entre o mapa e a referência
- O Kappa e outros índices calculados para um mapa específico tem pouca (ou nenhuma) utilidade prática. Esses índices são úteis apenas quando comparados a outros resultados. **Nunca** qualifique os valores de Kappa como “bom”, “alto”, etc.
- Ainda não há uma avaliação da significância dos índices propostos por Pontius, o que dificulta a comparação de resultados entre diferentes métodos de classificação
- Em geral, as avaliações da exatidão não consideram a componente espacial

Avaliação da Exatidão – Comentários Gerais

- Os erros encontrados deveriam apontar para melhoria no método de classificação
- Comumente, a coleta das amostras de validação é feita com base no mapa resultante da classificação. Se as amostras não forem distribuídas proporcionalmente a cada classe, índices relacionados ao produtor (referência) podem ser enviesados. Muitos autores apontam que sempre é melhor utilizar a matriz não enviesada (ajustada para as **proporções reais** de cada classe na classificação)
- As técnicas de reamostragem poderiam ser melhor aproveitadas para avaliações das incertezas, principalmente quando se dispõe de uma referência “completa” (por que confiar nos resultados de uma única amostragem?)

Avaliação de Classificação Binária

Em alguns casos, as classificações admitem apenas 2 classes: presente/ausente, ocorre/não ocorre, sim/não, positivo/negativo, etc

Nesse caso, a matriz de confusão teria a forma:

		Referência	
		Positivo	Negativo
Classificação	Positivo	Verdadeiro Positivo (VP)	Falso Positivo (FP)
	Negativo	Falso Negativo (FN)	Verdadeiro Negativo (VN)

$$exatidão = \frac{VP + VN}{VP + FP + FN + VN}$$

$$sensibilidade = \frac{VP}{VP + FN}$$


$$precisão = \frac{VP}{VP + FP}$$

$$F1\ score = 2 \frac{precisão * sensibilidade}{precisão + sensibilidade}$$

O *F1 score* é representa uma média balanceada entre a precisão e a sensibilidade

OBS: sensibilidade = revocação = *recall* = taxa de verdadeiros positivos – equivale à exatidão do produtor da classe positivo
precisão – equivale à exatidão do usuário da classe positivo

Exemplo - Detecção de corpos d'água




Landsat TM 5R4G3B


Amostras de treinamento:

- 30 de água
- 230 de não água


Qual teve melhor desempenho?




Mínima Distância



Mahalanobis




SVM




Rede Neural

Exemplo - Detecção de corpos d'água


Exemplo: Detecção de corpos d'água




Mínima Distância



Mahalanobis



SVM




Rede Neural

Amostras de teste:

- 35 de água
- 50 de não água

		Ref	
Class	MDist	Água	NÁgua
Água		32	2
NÁgua		3	48

		Ref	
Class	Mahal	Água	NÁgua
Água		32	3
NÁgua		3	47



		Ref	
Class	SVM	Água	NÁgua
Água		32	1
NÁgua		3	49


		Ref	
Class	RN	Água	NÁgua
Água		20	0
NÁgua		15	50

Geração de Mapas Binários por Fatiamento



Caso seja necessário a produção de um mapa a partir de uma métrica ou índice que representa uma probabilidade ou risco de ocorrência, é imprescindível a adoção de um limiar que irá definir a faixa de valores associados a classe desejada. Isso acontece em classificadores *fuzzy*, regressões logísticas e modelos de riscos em geral.

Essa mesma ideia pode ser aplicada quando se utiliza um índice espectral que maximiza a detecção de um determinado alvo (índices de vegetação, de água, de área construída, etc).


Mas como avaliar o desempenho de um método ou índice em discriminar esse alvo?




Landsat TM 5R4G3B



B3/B5




limiar 1



limiar 0,75

Curva ROC

O gráfico ROC (*Receiver Operating Characteristics*) pode ser usado para avaliar e comparar o desempenho de classificadores, ou definir o melhor limiar a ser utilizado. Permite ponderar a escolha entre benefícios (verdadeiros positivos) e custos (falsos positivos).




$$taxa\ VP = \frac{VP}{VP + FN} \quad (taxa\ VP = \text{sensibilidade} = \text{recall})$$

$$taxa\ FP = \frac{FP}{FP + VN} \quad (1 - taxa\ FP = \text{especificidade})$$

Quanto mais o resultado se aproximar do canto superior esquerdo (posição 0,1) melhor seu desempenho
A linha tracejada indica que o resultado representa uma estratégia aleatória, sem privilegiar os verdadeiros positivos em detrimento aos falsos positivos


Curva ROC



B3/B5


Amostras de treinamento:

- 75 de água
- 250 de não água



limiar	TVP	TFP
< 0,4316	1,000	1,000
0,4316	1,000	1,000
0,4476	1,000	0,996
0,4600	1,000	0,992
0,4615	1,000	0,988
0,4706	1,000	0,984
0,4715	1,000	0,980
0,4745	1,000	0,976
0,4762	1,000	0,972
0,4767	1,000	0,968
⋮	⋮	⋮
2,2778	0,120	0,000
2,2857	0,107	0,000
2,3158	0,093	0,000
2,3500	0,080	0,000
2,3636	0,067	0,000
2,3913	0,053	0,000
2,4286	0,040	0,000
2,4783	0,027	0,000
2,6667	0,013	0,000
>2,6667	0,000	0,000


Curva ROC



B3/B5

Amostras de treinamento:

- 75 de água
- 250 de não água




limiar	TVP	TFP
< 0,4316	1,000	1,000
0,4316	1,000	1,000
0,4476	1,000	0,996
0,4600	1,000	0,992
0,4615	1,000	0,988
0,4706	1,000	0,984
0,4715	1,000	0,980
0,4745	1,000	0,976
0,4762	1,000	0,972
0,4767	1,000	0,968
⋮	⋮	⋮
2,2778	0,120	0,000
2,2857	0,107	0,000
2,3158	0,093	0,000
2,3500	0,080	0,000
2,3636	0,067	0,000
2,3913	0,053	0,000
2,4286	0,040	0,000
2,4783	0,027	0,000
2,6667	0,013	0,000
>2,6667	0,000	0,000

AUC (Area Under the Curve)

Quanto mais próximo de 1, melhor é o modelo

Se for igual a 1, o modelo ou a classificação é capaz de separar perfeitamente os alvos!


Curva ROC



B3/B5

Amostras de treinamento:

- 75 de água
- 250 de não água




limiar	TVP	TFP
< 0,4316	1,000	1,000
0,4316	1,000	1,000
0,4476	1,000	0,996
0,4600	1,000	0,992
0,4615	1,000	0,988
0,4706	1,000	0,984
0,4715	1,000	0,980
0,4745	1,000	0,976
0,4762	1,000	0,972
0,4767	1,000	0,968
⋮	⋮	⋮
2,2778	0,120	0,000
2,2857	0,107	0,000
2,3158	0,093	0,000
2,3500	0,080	0,000
2,3636	0,067	0,000
2,3913	0,053	0,000
2,4286	0,040	0,000
2,4783	0,027	0,000
2,6667	0,013	0,000
>2,6667	0,000	0,000

Mas se o modelo (ou classificação) não for perfeito, como determinar o limiar que produza o melhor resultado?

- Aquele que mais se aproxima do ponto ideal (TFP=0 e TVP=1)
- Aquele que maximiza a Diferença entre TFP e TVP (Índice de Youden)
- Maximizar sensibilidade ou especificidade, ou outras métricas (exatidão ou F1-Score)


Curva ROC




B3/B5

Amostras de treinamento:

- 75 de água
- 250 de não água




limiar	TVP	TFP
< 0,4316	1,000	1,000
0,4316	1,000	1,000
0,4476	1,000	0,996
0,4600	1,000	0,992
0,4615	1,000	0,988
0,4630	1,000	0,984
0,4645	1,000	0,980
0,4660	1,000	0,976
0,4675	1,000	0,972
...	...	...
0,947	0,947	0,068
...	...	...
1,107	0,107	0,000
1,093	0,093	0,000
1,080	0,080	0,000
1,067	0,067	0,000
1,053	0,053	0,000
1,040	0,040	0,000
1,027	0,027	0,000
1,013	0,013	0,000
1,000	0,000	0,000



*mais próximo
maximiza


Curva ROC




B3/B5

Amostras de treinamento:

- 75 de água
- 250 de não água



limiar	TVP	TFP
< 0,4316	1,000	1,000
0,4316	1,000	1,000
0,4476	1,000	0,996
0,4600	1,000	0,992
0,4615	1,000	0,988
0,4706	1,000	0,984
0,4800	1,000	0,980
0,4900	1,000	0,976
0,5000	1,000	0,972
...	...	...
0,840	0,016	0,016
...	...	...
1,07	0,000	0,000
0,93	0,000	0,000
0,80	0,000	0,000
0,67	0,000	0,000
0,53	0,000	0,000
0,40	0,000	0,000
0,27	0,000	0,000
0,13	0,000	0,000
0,00	0,000	0,000




Mapas de Incerteza

Classificadores Probabilísticos

Os classificadores probabilísticos utilizam do conhecimento prévio da distribuição dos valores dos atributos referentes às classes de interesse para definir qual é a classe mais provável que um determinado elemento (ainda desconhecido) deve pertencer

Em geral, estas distribuições são desconhecidas e devem ser estimadas através de amostras (de treinamento)



Classes


- Floresta
- Regeneração
- Desmatamento
- Queimada
- Água

A definição das classes de interesse é etapa fundamental neste processo

Nesse caso, é importante conhecer o tipo de distribuição que o classificador é capaz de modelar!

Classificadores Probabilísticos

Um erro comum é confundir o que se quer classificar com a capacidade do classificador em representar a distribuição dos valores reais presentes na imagem



Supondo um classificador gaussiano...

Nos casos em que a distribuição parece ser bimodal (ClasseA), provavelmente há subclasses que devem ser separadas, o que resultaria num melhor desempenho do classificador

Dessa forma, deve-se definir muito mais classes do que o que se deseja e posteriormente estas classes podem ser agrupadas.

Exemplo: presença de nuvens!

Se a distribuição diferir muito da distribuição suposta válida, deve-se buscar outros classificadores...

Mapas de Incerteza

Usualmente a avaliação de uma classificação é feita através de índices globais (exatidão global, kappa, tau, etc) que refletem uma condição geral de acertos e erros mas podem esconder defeitos e qualidades locais

As incertezas oriundas da classificação são quase sempre ignoradas durante o processo de avaliação de um mapa temático

Mas como avaliar as incertezas espacialmente distribuídas?

- Definição explícita das incertezas do classificador: através da comparação das regras de decisão que levaram a escolha de uma dentre as várias classes possíveis (rotulação *soft*)
- Simulação Monte Carlo (quando não se tem acesso às regras de decisão): através da replicação do processo de classificação, a partir de diferentes amostras, gerando muitos mapas possíveis e contabilizando a frequência com que cada classe ocorreu nas diversas simulações

Medidas de Incerteza



Considerando um elemento w que pode ser atribuído a classe K_i dentre as C classes possíveis, podemos utilizar as seguintes medidas para representar a incerteza desta atribuição:

Baseando-se na **função de probabilidade** (ou proporção)


- **Entropia de Shannon** $H(w) = -\sum_{i=1}^C P(w \in K_i) \log_2 P(w \in K_i)$ $0 \leq H(w) \leq \log_2 C$ (o log pode ter outras bases)
- **Impureza de Gini** $G(w) = 1 - \sum_{i=1}^C P(w \in K_i)^2$ $0 \leq G(w) \leq \frac{1}{C}$
- **Razão de Incerteza** $RI(w) = 1 - \frac{\max[P(w \in K_i)] - \frac{1}{C}}{1 - \frac{1}{C}}$ $0 \leq RI(w) \leq 1$
- **Complementar da Probabilidade Máxima** $Cmax(w) = 1 - \max[P(w \in K_i)]$ $0 < Cmax(w) \leq 1$
- **Índice de Confusão** $IC(w) = \frac{P(w \in K_2)}{P(w \in K_1)}$ $P(w \in K_1) \geq P(w \in K_2) \geq \dots \geq P(w \in K_C)$ $0 < IC(w) \leq 1$

Mapas de Incerteza – Exemplo 1

LANDSAT 7 ETM O/P 230/62 RGB543 08 set 2002



Classificação MaxVer



Grades de Probabilidades

Classes

- Floresta (3262 pixels)
- Regeneração (379 pixels)
- Desmatamento (1371 pixels)
- Queimada (392 pixels)
- Água (1186 pixels)

Para diminuir os efeitos negativos da autocorrelação espacial, escolheu-se aleatoriamente apenas 10% dos pontos por classe


Estimam-se as médias, as variâncias/covariâncias das bandas para cada classe (ajuste de uma distribuição normal n-dimensional)

Calcula-se a probabilidade de cada pixel pertencer a cada classe


Mapa Final: classe com maior probabilidade

Classificador MaxVer Gaussiano

Mapas de Incerteza – Exemplo 1




Classificação MaxVer




Entropia de Shannon




Mapas de Incerteza – Exemplo 1



Classificação MaxVer




Entropia de Shannon



Mapas de Incerteza – Exemplo 1



Imagem TM RGB543





Entropia de Shannon




Mapas de Incerteza – Exemplo 2

LANDSAT 7 ETM O/P 230/62 RGB543 08 set 2002



Classificação Final



Grades de Proporções
Observadas nas
10.000 repetições


Classes

- Floresta (3262 pixels)
- Regeneração (379 pixels)
- Desmatamento (1371 pixels)
- Queimada (392 pixels)
- Água (1186 pixels)


Faz-se a classificação MaxVer escolhendo-se aleatoriamente apenas 10% dos pontos por classe
Repete-se este procedimento 10.000 vezes

Mapa Final: classe majoritária

Mapas de Incerteza – Exemplo 1 e 2



Entropia de Shannon – Exemplo 1



Entropia de Shannon – Exemplo 2



Considerações Importantes

Mapas de incerteza visam avaliar o desempenho do classificador

- Alta incerteza indica que o classificador não está conseguindo discriminar adequadamente as classes

- Espera-se que regiões com alta incerteza estejam associadas a maior ocorrência de erros

No entanto, áreas com baixa incerteza não implicam em altas exatidões

- Se o modelo/classificador for treinado para reconhecer uma classe errada, ele pode ainda assim “ter certeza” ao identificar aquela classe errada

Áreas com alta incerteza indicam que o classificador precisa ser melhorado

- Aumento do número de amostras


- Melhorar a definição das classes (dividir ou agrupar classes)

- Incluir novos atributos

- Em classificadores probabilísticos, as distribuições dos dados não são adequadas

Tamanho e Estratégia Amostral

Qual impacto do tamanho e estratégia amostral na avaliação do classificador?



Como avaliar o classificador?

- não se conhece a verdade (referência)
- não se tem ideia de onde estão os erros

Solução: selecionar um conjunto de pontos para verificação!

- quantos pontos selecionar?
- qual estratégia utilizar? aleatória? estratificada?

Qual índice utilizar? exatidão global? erro de comissão? erro de omissão?

Vamos Simular?

O que podemos esperar

- quanto mais amostras melhor!
- se for avaliar índices globais, abordagens que preservem a proporcionalidade entre classes, devem apresentar melhores resultados

Para isso, vamos supor que “exista” uma verdade que pode ser consultada





Imagem Classificada



“Verdade”

Experimentos

Vamos testar 3 tamanhos de amostras:

- 100 pontos (econômica)
- 300 pontos (indicada por Congalton e Olofsson)
- 1000 pontos (exagerada)

Vamos testar 3 abordagens de seleção de amostras:

- aleatória simples
 - estratificada* com amostragem proporcionais
 - estratificada* com amostragem de mesmo tamanho
- *usar a imagem classificada para estratificação (pois não se conhece a verdade)

Vamos avaliar:

- exatidão global
- erros de omissão
- erros de comissão

O processo de amostragem e avaliação será repetido 1000 vezes (poderia ser mais!)

Valores de Referência

Ao cruzar a imagem classificada com a referência, obtemos os seguintes resultados:

		Referência			
		Floresta	Desmat	Agua	
Class	Floresta	69,20%	0,13%	0,02%	69,35%
	Desmat	0,16%	26,19%	0,06%	26,40%
	Agua	0,10%	0,07%	4,08%	4,25%
		69,46%	26,39%	4,16%	100,00%

proporção observada

proporção real

ExatGlobal	Erro do Omissão			Erro do Comissão		
	Floresta	Desmat	Agua	Floresta	Desmat	Agua
99,47%	0,37%	0,75%	1,80%	0,21%	0,80%	3,94%

Amostragem Aleatória Simples




Imagem Classificada

Vantagem:

- Sorteio facilitado
- Em geral, preserva a proporcionalidade entre as classes

Desvantagens:

- A amostragem pode ficar "concentrada" numa região do mapa
- Tende a subamostrar classes mais raras, podendo gerar amostragens com classes "ausentes"
- A amostragem pode conter apenas 1 classe na imagem classificada ou na referência

Amostragem Estratificada Proporcional




Imagem Classificada

Vantagem:

- Garante que todas as classes sejam avaliadas
- Os erros de comissão são bem estimados

Desvantagens:

- Maior complexidade na amostragem
- Pode (raramente) não amostrar uma classe no mapa de referência (classes raras)
- Dificuldade em avaliar erros de classificação em classes majoritárias
- Maiores incertezas nas classes minoritárias

Floresta	69	208	694
Desmat	26	79	264
Agua	4	13	43
Total	99	300	1001

Mal representada

Amostragem Estratificada Mesmo Tamanho




Imagem Classificada

Vantagem:


- Garante que todas as classes sejam avaliadas
- Todas as classes são avaliadas com o mesmo nível de incerteza

Desvantagens:

- Maior complexidade na amostragem
- Pode (raramente) não amostrar uma classe no mapa de referência (classes raras)
- Dificuldade em avaliar erros de classificação em classes majoritárias
- Exatidão Global não representa toda a imagem classificada

Floresta	33	100	333
Desmat	33	100	333
Agua	33	100	333
Total	99	300	999

Exatidão Global



A estratificação usando mesmo tamanho de amostra para todas as classes prejudica a estimação da exatidão global pois nesse caso, perde-se a proporcionalidade de cada classe. E se corrigíssemos a matriz de confusão de modo a obter estimativas não enviesadas?

Exemplos de Matrizes de Confusão

Aleatória Simples

		Referência			
		Flor	Desm	Agua	
Class	Flor	675	1	0	676
	Desm	1	278	0	279
	Agua	2	3	40	45
		678	282	40	1000

Não enviesada $\hat{p}_{ij} = \frac{n_{ij}}{n_{i+}} \frac{N_{i+}}{N}$

		Referência			
		Flor	Desm	Agua	
Class	Flor	69,25%	0,10%	0,00%	69,35%
	Desm	0,09%	26,31%	0,00%	26,40%
	Agua	0,19%	0,28%	3,78%	4,25%
		69,53%	26,69%	3,78%	100,00%

Estratificada Proporcional

		Referência			
		Flor	Desm	Agua	
Class	Flor	694	0	0	694
	Desm	2	261	1	264
	Agua	2	0	41	43
		698	261	42	1001


		Referência			
		Flor	Desm	Agua	
Class	Flor	69,35%	0,00%	0,00%	69,35%
	Desm	0,20%	26,10%	0,10%	26,40%
	Agua	0,20%	0,00%	4,05%	4,25%
		69,75%	26,10%	4,15%	100,00%

Estratificada Mesmo Tamanho

		Referência			
		Flor	Desm	Agua	
Class	Flor	333	0	0	333
	Desm	1	331	1	333
	Agua	9	3	321	333
		343	334	322	999

		Referência			
		Flor	Desm	Agua	
Class	Flor	69,35%	0,00%	0,00%	69,35%
	Desm	0,08%	26,24%	0,08%	26,40%
	Agua	0,11%	0,04%	4,10%	4,25%
		69,54%	26,28%	4,18%	100,00%

Exatidão Global




Correção da matriz de confusão gerou pequeno impacto sobre as amostragens Aleatória Simples e Estratificada Proporcional.


Houve uma melhora significativa nas estimativas para a Estratificada de Mesmo Tamanho. Amostragens pequenas geram distribuições muito assimétricas com tendência muito forte a superestimar a exatidão global (mediana igual ou muito próxima a 100%!).

Em geral, amostragens maiores geram resultados muito semelhantes.

Erros de Comissão




Erros de Comissão



Com 100 amostras apenas, não foi possível avaliar o erro do usuário para classe Floresta (praticamente todas as estimativas foram iguais a zero!).
A explicação disso é que fica bem complicado “acertar” o erro muito raro numa classe tão abrangente (~70% da área total).

Erros de Comissão




Com o aumento do tamanho da amostra, diminui-se a incerteza aproximando-se a estimativa do valor de referência (mediana mais próxima do valor real).

Na Amostragem Proporcional de Mesmo Tamanho para $n = 300$, apenas 100 pontos foram amostrados!

A Amostragem Estratificada de Mesmo Tamanho para $n = 1000$ apresentou maior incerteza pois foram sorteados apenas 333 pontos sobre essa classe (nas outras abordagens a amostragem dessa classe foi de cerca de 690 amostras).


Erros de Comissão



É importante notar também que o erro de comissão para a classe Floresta, em geral foi subestimada mesmo quando 1000 amostras foram avaliadas.


O erro de comissão para a classe Floresta foi superestimado quando adotou-se a Amostragem Estratificada de Mesmo Tamanho, pois a classe Água, que apresentou o maior erro de comissão, foi relativamente mais amostrada (333 amostras), o que aumentou a chance de amostrar erros entre essas classes.

Erros de Comissão



Em geral, o mesmo comportamento foi observado para a classe Desmatamento. Amostragens pequenas foram insuficientes para estimar o erro de comissão dessa classe. O erro de comissão foi subestimado para as abordagens Aleatória Simples e Estratificada Proporcional quando 300 amostras foram selecionadas e foi exato quando 1000 amostras foram selecionadas (mediana próximo ao valor real). O erro de comissão dessa classe foi superestimado quando adotou-se a Amostragem Estratificada de Mesmo Tamanho (pelo mesmo motivo observado para classe Floresta).


Erros de Comissão




Para classe água, a Amostragem Estratificada de Mesmo Tamanho conseguiu estimar o erro de comissão mesmo quando apenas 100 amostras foram selecionadas já que nesse caso essa classe foi adequadamente estimada (33 amostras).

Também foi nessa abordagem amostral é que as estimativas foram mais precisas (relativamente, a classe Água recebe 1/3 das amostras mesmo representando apenas 4,25% da área classificada).

Erros de Omissão




Erros de Omissão



Em geral, a amostragem com 100 amostras não conseguiu estimar adequadamente o erro de omissão. Nesse caso, a Amostragem Estratificada de Mesmo Tamanho conseguiu estimar o erro de omissão (subestimando!) pois a classe Água, que possui os maiores erros, foi melhor amostrada.


Na Amostragem Aleatória Simples com apenas 100 amostras, há possibilidade de superestimar o erro de omissão caso essas poucas amostras caiam exatamente nos pontos de erro. Apenas amostragens com 1000 amostras conseguiram boas estimativas do erro de omissão.

Erros de Omissão



De modo geral, o mesmo foi observado para a classe Desmatamento com a diminuição da precisão nas estimativas do erro de omissão. A diferença se dá na Amostragem Estratificada de Mesmo Tamanho que subestimam o erro de omissão dessa classe, mesmo quando 1000 amostras foram avaliadas.

Erros de Omissão



O erro de omissão da classe Água só consegue ser estimada quando 1000 amostras foram avaliadas.

Resumo

As estratégias amostrais Aleatória Simples e Estratificada Proporcional chegam a resultados bastante semelhantes.

Entre essas duas abordagens, a precisão das estimativas é menor para a amostragem Aleatória Simples

Na Amostragem Estratificada de Mesmo Tamanho é essencial trabalhar com matrizes de confusão não enviesada.

O erro de comissão não é afetado pela correção da matriz de confusão quando utilizar a proporção de cada classe na classificação.

A estimação dos erros de comissão e omissão é prejudicada para classes majoritárias pois é mais difícil “acertar” os erros nessas classes quando esses erros são proporcionalmente pequenos.

As classes minoritárias são privilegiadas em Amostragens Estratificadas de Mesmo Tamanho (em detrimento às classes majoritárias).

De modo geral, quanto maior o número de amostras melhor será a estimativa dos índices e menor a importância de qual estratégia amostral adotada.